

第4章 无约束最优化方法

- 最优性条件
- 最速下降法
- 牛顿法、阻尼牛顿法
- 共轭方向法、共轭梯度法
- 变尺度法（*DFP*算法和*BFGS*算法）

第4章 无约束最优化方法

无约束最优化问题:

$$\min_{x \in R^n} f(x)$$

无约束最优化方法:

求解无约束优化问题的计算方法

最优化方法中的基本方法---无约束最优化方法

无约束最优化方法:

- 应用广泛;
- 理论也比较成熟;
- 约束优化可转化为无约束优化

$$\text{令 } F(x) = \begin{cases} f(x), & x \in D \\ +\infty, & x \notin D. \end{cases}$$

$$\text{则 } \min_{x \in D} f(x) = \min_{x \in R^n} F(x),$$

最优化方法中的基本方法---无约束优化方法

无约束优化方法 本章介绍解析法	解析法:利用函数的一阶或二阶导数的方法 收敛速度快, 需要计算梯度或者Hesse矩阵 可求得目标函数的梯度时使用解析法 直接法:仅利用函数值的信息, 寻找最优解 不涉及导数, 适用性强, 但收敛速度慢 在不能求得目标函数的梯度或偏导数时使用直接法
------------------------	--

本章内容

- 最优性条件
- 最速下降法
- 牛顿法、阻尼牛顿法
- 共轭方向法、共轭梯度法
- 变尺度法（*DFP*算法和*BFGS*算法）

最优性条件(Optimality Conditions)

最优性条件

- 优化问题的(局部或全局)最优解所必须满足的条件;
- 常见的一阶必要条件和二阶充分条件;
- 是优化算法建立和分析的基础;
- 对于优化理论的研究具有重要意义。

无约束优化的最优性条件----一阶必要条件

定理(一阶必要条件)

设 $f: R^n \rightarrow R$, 若 x^* 为 f 的局部极小点, 且在 $N_\epsilon(x^*)$ 内连续可微, 则 $\nabla f(x^*) = 0$.

定理3 (必要条件)

设 $f: D \subseteq R^n \rightarrow R$
 (1) x^* 为 D 的一个内点;
 (2) f 在 x^* 可微;
 (3) x^* 为 f 的极值点;
 则 $\nabla f(x^*) = 0$.

无约束优化的最优性条件----二阶必要条件

定理 (二阶必要条件)

若 x^* 为 f 的局部极小点, 且在 $N_\epsilon(x^*)$ 内 f 二次连续可微, 则 $\nabla f(x^*) = 0, \nabla^2 f(x^*)$ 半正定。

无约束优化的最优性条件----二阶充分条件

定理(二阶充分条件)

设 $f: R^n \rightarrow R$, 若 $\nabla f(x^*) = 0$, f 在 $N_\varepsilon(x^*)$ 内二次连续可微,

且 $\nabla^2 f(x^*)$ 正定, 则 x^* 为 f 的严格局部极小点。

如果 $\nabla^2 f(x^*)$ 负定, 则 x^* 为 f 的严格局部极大点。

定理4(充分条件) 设 $f: D \subseteq R^n \rightarrow R$

(1) x^* 为 D 的一个内点;

(2) f 在 x^* 二次连续可微;

(3) $\nabla f(x^*) = 0$;

(4) $\nabla^2 f(x^*)$ 正定;

则 x^* 是 f 的严格局部极小点。

无约束凸优化的最优性条件----一阶条件

定理(一阶充要条件)

设 $f: R^n \rightarrow R$ 是凸函数且在 x^* 处连续可微, 则 x^* 为 f 的全局极小点的充要条件是 $\nabla f(x^*) = 0$.

定理

设 $f: R^n \rightarrow R$ 是严格凸函数且在 x^* 处连续可微, 若

$\nabla f(x^*) = 0$, 则 x^* 为 f 的唯一全局极小点。

无约束优化的最优性条件

例 利用最优性条件求解下列问题:

$$\min f(x) = \frac{1}{3}x_1^3 + \frac{1}{3}x_2^3 - x_2^2 - x_1.$$

解 $\frac{\partial f}{\partial x_1} = x_1^2 - 1, \frac{\partial f}{\partial x_2} = x_2^2 - 2x_2,$

令 $\nabla f(x) = 0$, 即

$$\begin{cases} x_1^2 - 1 = 0 \\ x_2^2 - 2x_2 = 0, \end{cases}$$

得到驻点: $x_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, x_2 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, x_3 = \begin{pmatrix} -1 \\ 0 \end{pmatrix}, x_4 = \begin{pmatrix} -1 \\ 2 \end{pmatrix}.$

利用一阶条件
求驻点

利用二阶条件
判断驻点是否
是极小点

无约束优化的最优性条件

函数 f 的 Hesse 阵:

$$\nabla^2 f(x) = \begin{pmatrix} 2x_1 & 0 \\ 0 & 2x_2 - 2 \end{pmatrix},$$

利用二阶条件
判断驻点是否
是极小点

在点 x_1, x_2, x_3, x_4 处的 Hesse 阵依次为:

$$\nabla^2 f(x_1) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}, \quad \nabla^2 f(x_2) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix},$$

$$\nabla^2 f(x_3) = \begin{pmatrix} -2 & 0 \\ 0 & -2 \end{pmatrix}, \quad \nabla^2 f(x_4) = \begin{pmatrix} -2 & 0 \\ 0 & 2 \end{pmatrix}.$$

$$x_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad x_2 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad x_3 = \begin{pmatrix} -1 \\ 0 \end{pmatrix}, \quad x_4 = \begin{pmatrix} -1 \\ 2 \end{pmatrix}.$$

无约束优化的最优性条件

$\nabla^2 f(x_1) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$, $\nabla^2 f(x_4) = \begin{pmatrix} -2 & 0 \\ 0 & 2 \end{pmatrix}$ 的行列式小于0;

x_1, x_4 是鞍点;

$\nabla^2 f(x_2) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$ 是正定矩阵;

x_2 是极小点;

$\nabla^2 f(x_3) = \begin{pmatrix} -2 & 0 \\ 0 & -2 \end{pmatrix}$ 是负定矩阵;

x_3 是极大点。

- 对某些较简单的函数，这样做有时是可行的；
- 但对一般 n 元函数 f 来说，由 $\nabla f(x)=0$ 得到的是一个非线性方程组，求解相当困难。
- 常使用迭代法直接求解无约束优化问题。

根据迭代点是否沿某个方向产生

线搜索方法：迭代点沿某方向产生 信赖域方法：迭代点在某区域内搜索产生

线搜索迭代法的步骤

步骤1 选定初始点 x^1 ，并令 $k:=1$ ；

步骤2 检验 x^k 是否满足终止条件，若满足，则停止迭代，否则，转步骤3。

步骤3 确定搜索方向 d^k ；

步骤4 从 x^k 出发，沿方向 d^k 求步长 λ_k ，产生下一个迭代点 x^{k+1} ；令 $k:=k+1$ ，转步骤2。

步长可以是最佳步长、可接受步长、固定步长；

不同的搜索方向，对应着不同的算法。

最速下降法

负梯度方向 这是函数值减少最快的方向

假设 f 连续可微，取

$$d^k = -\nabla f(x^k),$$

$$\lambda_k = \arg \min_{\lambda \geq 0} f(x^k + \lambda d^k),$$

从而得到第 $k+1$ 次迭代点，即

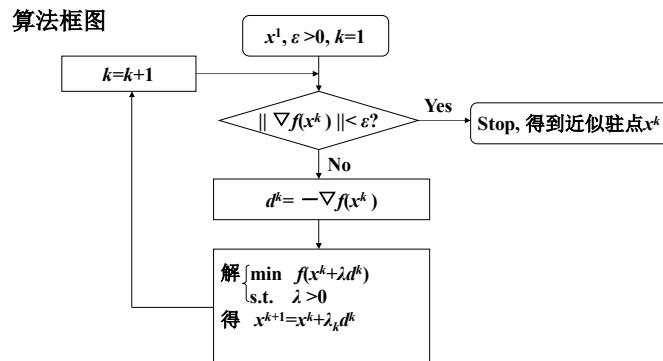
$$x^{k+1} = x^k + \lambda_k d^k = x^k - \lambda_k \nabla f(x^k).$$

最速下降法是求多元函数极值的最古老的数值算法，早在1847年法国数学家Cauchy提出该算法，后来Curry作了进一步的研究。

最速下降法--算法步骤

- 步骤1 选定初始点 $x^1, \varepsilon > 0$, 并令 $k=1$.
- 步骤2 若 $\|\nabla f(x^k)\| \leq \varepsilon$, 算法终止, 得到近似驻点 x^k ,
否则转步骤3.
- 步骤3 令 $d^k = -\nabla f(x^k)$.
- 步骤4 确定最佳步长 $\lambda_k = \arg \min f(x^k + \lambda d^k)$,
令 $x^{k+1} = x^k + \lambda_k d^k, k=k+1$, 转步骤2.

最速下降法--算法框图



最速下降法--算例

例 利用最速下降法求解 $\min f(x) = x_1^2 + 2x_2^2 - 2x_1x_2 - 4x_1$,
取 $x^1 = (1, 1)^T, \varepsilon = 10^{-2}$.
解 函数的梯度为 $\nabla f(x) = \begin{pmatrix} 2x_1 - 2x_2 - 4 \\ -2x_1 + 4x_2 \end{pmatrix}, \quad x^* = (4, 2)^T$.

第1次迭代

$$\nabla f(x^1) = \begin{pmatrix} -4 \\ 2 \end{pmatrix}, \quad d^1 = -\nabla f(x^1) = \begin{pmatrix} 4 \\ -2 \end{pmatrix},$$

$$x^1 + \lambda d^1 = \begin{pmatrix} 1+4\lambda \\ 1-2\lambda \end{pmatrix},$$

$$\varphi(\lambda) = f(x^1 + \lambda d^1) = f(1+4\lambda, 1-2\lambda)$$

$$= (1+4\lambda)^2 + 2(1-2\lambda)^2 - 2(1+4\lambda)(1-2\lambda) - 4(1+4\lambda) = 40\lambda^2 - 20\lambda - 3$$

令 $0 = \varphi'(\lambda) = 80\lambda - 20$, 得 $\lambda_1 = 1/4$,

最速下降法--算例

$$\nabla f(x) = \begin{pmatrix} 2x_1 - 2x_2 - 4 \\ -2x_1 + 4x_2 \end{pmatrix}, \quad x^1 = (1, 1)^T, \quad \lambda_1 = 1/4, \quad d^1 = \begin{pmatrix} 4 \\ -2 \end{pmatrix},$$

$$x^2 = x^1 + \lambda_1 d^1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} + 1/4 \begin{pmatrix} 4 \\ -2 \end{pmatrix} = \begin{pmatrix} 2 \\ 1/2 \end{pmatrix}, \quad \nabla f(x^2) = \begin{pmatrix} -1 \\ -2 \end{pmatrix},$$

第2次迭代

$$d^2 = -\nabla f(x^2) = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad x^2 + \lambda d^2 = \begin{pmatrix} 2+\lambda \\ 1/2+2\lambda \end{pmatrix},$$

$$\varphi(\lambda) = f(x^2 + \lambda d^2) = f(2+\lambda, 1/2+2\lambda)$$

$$= (2+\lambda)^2 + 2(1/2+2\lambda)^2 - 2(2+\lambda)(1/2+2\lambda) - 4(2+\lambda) = 5\lambda^2 - 5\lambda - 11/2$$

令 $0 = \varphi'(\lambda) = 10\lambda - 5$, 得 $\lambda_2 = 1/2$,

$$x^3 = x^2 + \lambda_2 d^2 = \begin{pmatrix} 2 \\ 1/2 \end{pmatrix} + 1/2 \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 5/2 \\ 3/2 \end{pmatrix}, \quad \nabla f(x^3) = \begin{pmatrix} -2 \\ 1 \end{pmatrix}$$

最速下降法--算例

$$\nabla f(x) = \begin{pmatrix} 2x_1 - 2x_2 - 4 \\ -2x_1 + 4x_2 \end{pmatrix}, \quad x^3 = \begin{pmatrix} 5/2 \\ 3/2 \end{pmatrix}, \quad \nabla f(x^3) = \begin{pmatrix} -2 \\ 1 \end{pmatrix},$$

第3次迭代

$$d^3 = -\nabla f(x^3) = \begin{pmatrix} 2 \\ -1 \end{pmatrix}, \quad x^3 + \lambda d^3 = \begin{pmatrix} 5/2 + 2\lambda \\ 3/2 - \lambda \end{pmatrix},$$

$$\varphi(\lambda) = f(x^3 + \lambda d^3) = f(5/2 + 2\lambda, 3/2 - \lambda) \\ = (5/2 + 2\lambda)^2 + 2(3/2 - \lambda)^2 - 2(5/2 + 2\lambda)(3/2 - \lambda) - 4(5/2 + 2\lambda) = 10\lambda^2 - 5\lambda - 27/4$$

$$\text{令 } 0 = \varphi(\lambda) = 20\lambda - 5, \text{ 得 } \lambda_3 = 1/4,$$

$$x^4 = x^3 + \lambda_3 d^3 = \begin{pmatrix} 5/2 \\ 3/2 \end{pmatrix} + 1/4 \begin{pmatrix} 2 \\ -1 \end{pmatrix} = \begin{pmatrix} 3 \\ 5/4 \end{pmatrix}, \quad \nabla f(x^4) = \begin{pmatrix} -1/2 \\ -1 \end{pmatrix},$$

经17次迭代，满足终止条件，得到近似极小点 $x^* = (3.99, 1.99)^T$.**最速下降法--两个特征****1. 相邻两次迭代的搜索方向正交**

$$\text{令 } \varphi(\lambda) = f(x^k + \lambda d^k),$$

利用精确一维搜索，可得

$$\varphi'(\lambda_k) = (\nabla f(x^k + \lambda_k d^k))^T d^k = 0$$

由此得出

$$-\nabla f(x^k) = d^k$$

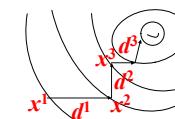
$$0 = (\nabla f(x^k + \lambda_k d^k))^T d^k = (\nabla f(x^{k+1}))^T d^k = -(d^{k+1})^T d^k$$

最速下降法在相邻两次迭代的搜索方向是正交的。**最速下降法--两个特征****1. 相邻两次迭代的搜索方向正交** $(d^{k+1})^T d^k = 0$ 最速下降法在求 f 的极小点时，会发生锯齿现象

- 相邻两次迭代的搜索方向正交，使得迭代点向极小点的逼近是曲折前进的，这种现象称为锯齿现象；
- 对于一般的目标函数都会发生；
- 一些特殊的目标函数不会发生锯齿现象；
- 某些特殊的初始点不会发生锯齿现象。

最速下降法--两个特征

注：在最速下降法中，利用精确一维搜索求最佳步长，导致相邻两次迭代的搜索方向总是正交的，

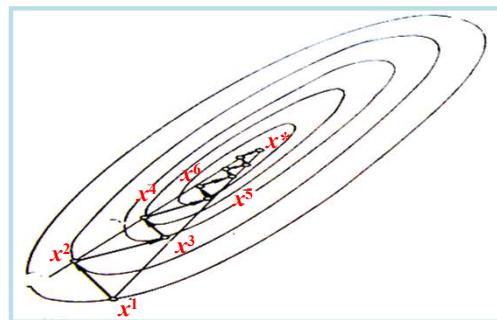


从而使得迭代点逼近极小点的过程是“之”字形。

从任何一个初始点开始，都可以很快到达极小点附近，但是越靠近极小点移动越慢，导致最速下降法的收敛速度很慢。

最速下降法--两个特征

2. 给定二元正定二次函数，用最速下降法求其极小点，算法产生点列：偶数点列均在一条直线上，奇数点列也均在一条直线上，且都过极小点。



给定二元正定二次函数 $f(x) = \frac{1}{2}x^T Ax + b^T x + c$, 用最速下降法求其极小点，产生点列：偶数点列均在一条直线上，奇数点列也均在一条直线上，且都过极小点。

分析：因为相邻方向正交，极小点为 $-A^{-1}b$,

则 $d^2 // d^4 // \dots // d^{2k}$

$\exists t, d^{2k} = t d^2$ t 与 k 有关

$$\therefore Ax^{2k} + b = t(Ax^2 + b) \quad (\because d^k = -\nabla f(x^k) = -Ax^k - b)$$

$$\therefore A(x^{2k} + A^{-1}b) = tA(x^2 + A^{-1}b) = A(t(x^2 + A^{-1}b))$$

$$\therefore x^{2k} + A^{-1}b = t(x^2 + A^{-1}b),$$

故偶数点列共线，且过极小点。

最速下降法--收敛性分析

收敛性定理

设 f 连续可微，水平集 $L = \{x | f(x) \leq f(x^1)\}$ 有界，则最速下降法或者在有限迭代步后得到驻点，或者得到点列 $\{x^k\}$ ，其任何聚点都是 f 的驻点。

推论

在收敛定理的假设下，若 f 为凸函数，则最速下降法或在有限迭代步后达到极小点，或得到点列 $\{x^k\}$ ，其任何聚点都是 f 的极小点。

用于二次函数时的收敛速度分析

定理 设二次函数 $f(x) = \frac{1}{2}x^T Ax$, A 对称正定， λ_1, λ_2 分别为其最小和最大特征值，从任意初点 x^1 出发，用最速下降法求 f 的极小点，产生的序列 $\{x^k\}$ ，对于 $k \geq 2$ 有

$$f(x^k) \leq \left(\frac{\lambda_2 - \lambda_1}{\lambda_2 + \lambda_1}\right)^2 f(x^{k-1}), \quad \|x^k\| \leq \sqrt{\frac{\lambda_2}{\lambda_1}} \left(\frac{\lambda_2 - \lambda_1}{\lambda_2 + \lambda_1}\right)^k \|x^1\|,$$

由于 $\frac{\lambda_2 - \lambda_1}{\lambda_2 + \lambda_1} < 1$, 则 $x^k \rightarrow 0$.

函数 $f(x) = \frac{1}{2}x^T Ax$ 的极小点恰好是 $x^* = 0$. 故从任意初点出发，最速下降法求解二次函数均收敛，且是线性收敛。

用于二次函数时的收敛速度分析

下面说明最速下降法收敛性的几何意义。

考虑A为正三角矩阵时的二次函数

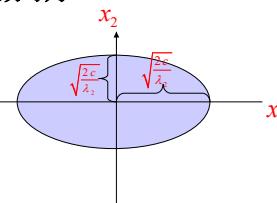
$$f(x) = \frac{1}{2}x^T Ax = \frac{1}{2}(\lambda_1 x_1^2 + \lambda_2 x_2^2), \quad A = \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix}$$

其中 $\lambda_2 \geq \lambda_1 > 0$

函数的等值线为 $f(x_1, x_2) = c, c > 0$, 可改写为

$$\frac{x_1^2}{\left(\sqrt{\frac{2c}{\lambda_1}}\right)^2} + \frac{x_2^2}{\left(\sqrt{\frac{2c}{\lambda_2}}\right)^2} = 1,$$

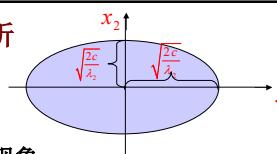
这是以 $\sqrt{\frac{2c}{\lambda_1}}$ 和 $\sqrt{\frac{2c}{\lambda_2}}$ 为半轴的椭圆。



用于二次函数时的收敛速度分析

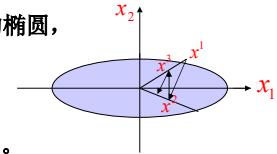
(2) 当 $\lambda_1 < \lambda_2$ 时, 等值线为椭圆。

此时对于一般的初始点将产生锯齿现象。



(3) 当 $\lambda_1 \ll \lambda_2$ 时, 等值线是很扁的椭圆,

此时 $\frac{\lambda_2 - \lambda_1}{\lambda_2 + \lambda_1} \approx 1$, 对于一般的初始点,



收敛速度十分缓慢, 锯齿现象严重。

等值线为椭圆的目标函数,
存在锯齿现象;

椭圆越扁, 锯齿现象越严重

$$\|x^k\| \leq \sqrt{\frac{\lambda_2}{\lambda_1}} \left(\frac{\lambda_2 - \lambda_1}{\lambda_2 + \lambda_1} \right)^k \|x^0\|$$

从下面的分析可见 两个特征值 λ_1, λ_2
的相对大小决定最速下降法的收敛性。

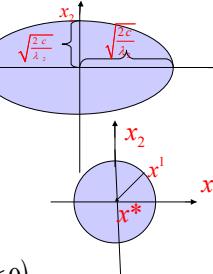
(1) 当 $\lambda_1 = \lambda_2$ 时, 等值线变为圆,

$$\text{此时 } \frac{\lambda_2 - \lambda_1}{\lambda_2 + \lambda_1} = 0,$$

由上述定理可知: $x^2 = 0 (\because 0 \leq \|x^2\| \leq 0)$.

故迭代一步就到了极小点, 这表明最速下降法用于等值线
为圆的目标函数时, 只需迭代一步就到了极小点。

等值线为圆的目标函数, $\|x^k\| \leq \sqrt{\frac{\lambda_2}{\lambda_1}} \left(\frac{\lambda_2 - \lambda_1}{\lambda_2 + \lambda_1} \right)^k \|x^0\|$
不存在锯齿现象



最速下降法--优缺点

优点: 理论明确, 程序简单;

每次的计算量小, 存储量小;

对初始点要求不严格。

缺点: 收敛慢 (最速下降方向是某点的局部性质)。

最速下降法相邻两次搜索方向的正交性, 决定了
迭代全过程的搜索路线呈锯齿状, 远快近慢。

最速下降法--优缺点

最速下降法

- 是无约束优化的基本方法之一；
- 不是好的实用算法；
- 一些有效算法是通过对它的改进或与其它收敛快的算法结合而得到的。

最速下降法--改进

(1) 选择不同初始点

例 $\min f(x) = x_1^2 + 25x_2^2$, 取初始点 $x^1 = (2, 2)^T$.

第1次迭代

$$\nabla f(x^1) = (4, 100)^T, d^1 = -\nabla f(x^1) = (-4, -100)^T$$

$$x^1 + \lambda d^1 = (2 - 4\lambda, 2 - 100\lambda)^T$$

$$\varphi(\lambda) = f(2 - 4\lambda, 2 - 100\lambda) = (2 - 4\lambda)^2 + 25(2 - 100\lambda)^2$$

$$\text{令 } 0 = \varphi'(\lambda) = -8(2 - 4\lambda) - 5000(2 - 100\lambda), \text{ 得 } \lambda_1 = \frac{626}{31252} \approx 0.02003072,$$

$$x^2 = x^1 + \lambda_1 d^1 = (1.919877, -0.3071785 \times 10^{-2})^T$$

最速下降法--改进

$$x^2 = (1.919877, -0.3071785 \times 10^{-2})^T$$

然后再从 x^2 开始新的迭代，

经过69次迭代，满足终止条件，

得到近似极小点 $x^* = (0.0042, 0.0001)^T$.

最速下降法--改进

如果初始点不取 $x^1 = (2, 2)^T$ 而取 $x^1 = (100, 0)^T$,

第1次迭代

$$x^1 = (100, 0)^T, \nabla f(x^1) = (2x_1^1, 50x_2^1) = (200, 0)^T,$$

$$d^1 = -\nabla f(x^1) = (-200, 0)^T,$$

$$\varphi(\lambda) = f(100 - 200\lambda, 0 - 0\lambda) = (100 - 200\lambda)^2 + 25(0 - 0\lambda)^2,$$

$$0 = \varphi'(\lambda) = \frac{d}{d\lambda} [(100 - 200\lambda)^2 + 25(0 - 0\lambda)^2] = -400(100 - 200\lambda)$$

$$\lambda_1 = \frac{1}{2}, \quad x^2 = x^1 + \lambda_1 d^1 = (100, 0)^T + 1/2(-200, 0)^T = (0, 0)^T.$$

一步迭代得到了极小点

最速下降法--改进

如果初始点不取 $x^1 = (2, 2)^T$ 而取 $x^1 = (100, 0)^T$, 一步迭代得到极小点。

虽然 $(100, 0)^T$ 离极小点 $x^* = (0, 0)^T$ 更远,

但是迭代中没有出现锯齿现象。

锯齿现象的出现与初始点的选择有关,
选择合适的初始点可以不出现锯齿现象。

怎么选?  很困难

最速下降法--改进

为了清除最速下降法中两个搜索方向正交的不良后果, 提出了许多改进的方法, 如:

(2) 不采用精确一维搜索

可使 $(d^{k+1})^T d^k \neq 0$, 从而改变最速下降法的收敛性。

- 采用非精确一维搜索求得的可接受步长
- 采用固定步长  固定步长最速下降法
 - 固定步长取几, 1还是2, 还是别的值, 没有标准;
 - 步长取小了, 收敛慢;
 - 步长取大了, 会漏掉极小点。

最速下降法--改进

(3) 采用加速梯度法 负梯度方向和 $d^k = x^k - x^{k-2}$ 结合

Shah等人于1964年提出了一种“平行切线法”(简记为PARTAN法), 又称加速梯度法。

搜索方向可取 $d^k = x^k - x^{k-2}$,

下两步继续用最速下降方向即负梯度方向,

这两种方向交替使用, 效用要比最速下降法好的多。

Newton法

精确一维搜索中介绍了Newton法, 即用目标函数的二阶Tayloy展开式近似代替目标函数, 用二阶Tayloy展开式的极小点估计目标函数的极小点。

 可推广到多维的情形

Newton法是求解无约束极小化问题的最古老的算法之一, 现已发展成一类算法——Newton型方法。

Newton法

精确一维搜索中的Newton迭代公式

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)},$$

多维无约束优化中的Newton迭代公式

$$x^{k+1} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k).$$

Newton法-- 基本思路

在 x^k 处对函数 f 作二阶 Taylor 展开: $f(x) = f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2} (x - x^k)^T \nabla^2 f(x^k) (x - x^k) + o(\|x - x^k\|^2)$

略去高阶项,

$$f(x) \approx Q(x) \approx f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2} (x - x^k)^T \nabla^2 f(x^k) (x - x^k),$$

$$\text{令 } \nabla Q(x) = \nabla f(x^k) + \nabla^2 f(x^k)(x - x^k) = 0,$$

若 $\nabla^2 f(x^k) (= \nabla^2 Q(x))$ 正定, 则二次函数的极小点为:

$$x^{k+1} := x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k), \quad \rightarrow \text{Newton 迭代公式}$$

以 x^{k+1} 作为 f 极小点的一个新的估计。

Newton法--算法步骤

求函数 f 的极小点, 给定误差限 ε .

步骤1 选定初始点 x^1 , 计算 $f_1 = f(x^1), k=1$.

步骤2 如果 $\|\nabla f(x^k)\| \leq \varepsilon$, 停止, 得到近似驻点 x^k , 否则转步骤3.

步骤3 计算搜索方向 $d^k = -(\nabla^2 f(x^k))^{-1} \nabla f(x^k)$

步骤4 令 $x^{k+1} = x^k + d^k, k = k+1$, 转步骤2.

步长取常数1

Newton法--算法步骤

步骤1 选定初始点 x^1 , 计算 $f_1 = f(x^1), k=1$.

步骤2 如果 $\|\nabla f(x^k)\| \leq \varepsilon$, 停止, 得到近似驻点 x^k , 否则转步骤3.

步骤3 计算搜索方向 $d^k = -(\nabla^2 f(x^k))^{-1} \nabla f(x^k)$.

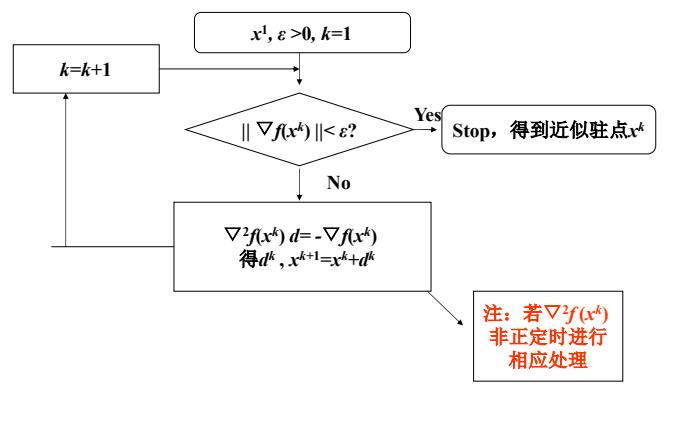
步骤4 令 $x^{k+1} = x^k + d^k, k = k+1$, 转步骤2.

步骤3中的搜索方向 d^k , 可通过求解下列方程组得到

$$\nabla^2 f(x^k) d^k + \nabla f(x^k) = 0.$$

- 已有标准程序解线性方程组;
- 减少计算量。

Newton法--算法框图



Newton法——算例

例 用Newton法求 $f(x_1, x_2) = x_1^2 + 25x_2^2$ 的极小点。

解 取初始点 $x^1 = (2, 2)^T$,

$$\text{计算 } \nabla f(x^1) = \begin{pmatrix} 2x_1 \\ 50x_2 \end{pmatrix} \Big|_{x^1} = \begin{pmatrix} 4 \\ 100 \end{pmatrix}, \nabla^2 f(x^1) = \begin{pmatrix} 2 & 0 \\ 0 & 50 \end{pmatrix},$$

代入Newton迭代公式,

$$x^2 = x^1 - (\nabla^2 f(x^1))^{-1} \nabla f(x^1) = \begin{pmatrix} 2 \\ 2 \end{pmatrix} - \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{50} \end{pmatrix} \begin{pmatrix} 4 \\ 100 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

得到问题的极小点 $x^* = x^2$.

一步即达到最优解

利用Newton法求n元正定二次函数的极小点，从任意初始点出发，一步迭代即可达到极小点。

设 $f(x) = 1/2x^T Ax + b^T x + c$, 其中 $A_{n \times n}$ 对称正定, $b \in R^n, c \in R$.

f 的极小点是 f 等值面的中心, $x^* = -A^{-1}b$.

下面用Newton法求 f 的极小点:

$$\forall x^1 \in R^n, \nabla f(x^1) = Ax^1 + b, \nabla^2 f(x^1) = A,$$

$$x^2 = x^1 - (\nabla^2 f(x^1))^{-1} \nabla f(x^1) = x^1 - A^{-1}(Ax^1 + b) = -A^{-1}b.$$

一步达到最优解

Newton法-- 基本思路

$$\begin{aligned} \text{在 } x^k \text{ 处对函数 } f \text{ 作二阶 Taylor 展开: } f(x) &= f(x^k) + \nabla f(x^k)^T (x - x^k) \\ &\quad + \frac{1}{2} (x - x^k)^T \nabla^2 f(x^k) (x - x^k) + o(\|x - x^k\|^2) \end{aligned}$$

略去高阶项,

$$f(x) \approx Q(x) \approx f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2} (x - x^k)^T \nabla^2 f(x^k) (x - x^k),$$

$$\text{令 } \nabla Q(x) = \nabla f(x^k) + \nabla^2 f(x^k)(x - x^k) = 0,$$

若 $\nabla^2 f(x^k)$ ($= \nabla^2 Q(x)$) 正定，则二次函数的极小点为：

$$x^{k+1} := x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k), \quad \xrightarrow{\text{Newton}} \text{Newton 迭代公式}$$

以 x^{k+1} 作为 f 极小点的一个新的估计。

利用Newton法求 n 元正定二次函数的极小点，从任意初始点出发，一步迭代即可达到极小点。

Newton法具有二次收敛性

二次收敛性（二次终止性）

从任意初始点出发，经有限次迭代总可以达到 n 元正定二次函数的极小点，称这样的算法具有二次收敛性。

Newton法比最速下降法收敛快。

Newton法：局部二阶收敛

当初始点靠近极小点时，Newton法的收敛速度很快。

当初始点远离极小点时，Newton法可能不收敛，甚至连下降性都保证不了。

Newton法--优缺点

优点：算法收敛速度快(初始点离极小点很近);

不需要进行一维搜索；

对 n 元正定二次函数，迭代一次就可得到极小点。

Newton法--优缺点

缺点：(1) 对多数算法不具有全局收敛性；

(2) 每次迭代都要计算Hesse矩阵，计算量大；

(3) 每次迭代都要计算 $(\nabla^2 f(x^k))^{-1}$ 或者求解方程组
 $\nabla^2 f(x^k)d + \nabla f(x^k) = 0$ ，

- $(\nabla^2 f(x^k))^{-1}$ 可能不存在；
- 方程组是奇异的，病态的；
- $\nabla^2 f(x^k)$ 非正定， d^k 可能不是下降方向。

(4) 收敛于鞍点或极大点的可能性并不小。

当 $\nabla^2 f(x^k)$ 正定时，

$$(\nabla f(x^k))^T d^k = -(\nabla f(x^k))^T (\nabla^2 f(x^k))^{-1} \nabla f(x^k) < 0.$$

Newton法--改进

Newton法的优点和缺点都很突出，本身并不实用；
对Newton法进行改进，可得到求解无约束优化的有效方法。
怎么改进呢？保留Newton法的优点，克服部分缺点。

针对Newton法的缺点(1)对多数算法不具有全局收敛性，
和(4)收敛于鞍点或极大点的可能性并不小，
步长不取固定值1，而是采用精确一维搜索
 $\min f(x^k + \lambda d^k)$
找最佳步长 λ_k ，这就是**阻尼Newton法**。

Newton法的改进----阻尼Newton法

在Newton迭代公式中，

$$x^{k+1} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k),$$

加入精确一维搜索： $\min f(x^k + \lambda d^k)$

每次迭代目标函数值一定有所下降
求得最佳步长 λ_k ，得到下个迭代点 $x^{k+1} = x^k + \lambda_k d^k$ 。

这样修正之后通常可改进Newton法的缺点(1)和(4)。
缺点(1)对多数算法不具有全局收敛性：
(4)收敛于鞍点或极大点的可能性并不小；

Newton法的改进----阻尼Newton法

收敛性定理

设 f 存在二阶连续偏导数， $\nabla^2 f(x)$ 正定，水平集
 $L = \{x | f(x) \leq f(x^1)\}$ 有界，则阻尼Newton法或在有限
迭代步后得到极小点，或得到无穷点列 $\{x^k\}$ ，
(1) $\{f(x^k)\}$ 为严格单调下降序列且 $\lim_{k \rightarrow \infty} f(x^k)$ 存在；
(2) $\{x^k\}$ 有唯一聚点 x^* ，它是 f 的极小点。

特点：全局收敛

例 用阻尼Newton法求下列无约束优化的极小点，已知

$$f(x) = x_1^2 + 2x_2^2 - 2x_1x_2 - 4x_1, x^1 = (1, 1)^T, \varepsilon = 10^{-2}.$$

解：

$$\text{计算 } \nabla f(x^1) = \begin{pmatrix} 2x_1 - 2x_2 - 4 \\ -2x_1 + 4x_2 \end{pmatrix} \Big|_{x=x^1} = \begin{pmatrix} -4 \\ 2 \end{pmatrix},$$

$$\nabla^2 f(x^1) = \begin{pmatrix} 2 & -2 \\ -2 & 4 \end{pmatrix} \Big|_{x=x^1} = \begin{pmatrix} 2 & -2 \\ -2 & 4 \end{pmatrix},$$

$$\text{故 } d^1 = -(\nabla^2 f(x^1))^{-1} \nabla f(x^1) = -\begin{pmatrix} 2 & -2 \\ -2 & 4 \end{pmatrix}^{-1} \begin{pmatrix} -4 \\ 2 \end{pmatrix}$$

$$= -\begin{pmatrix} 1 & 1/2 \\ 1/2 & 1/2 \end{pmatrix} \begin{pmatrix} -4 \\ 2 \end{pmatrix} = \begin{pmatrix} 3 \\ 1 \end{pmatrix},$$

$$x^1 + \lambda d^1 = \begin{pmatrix} 1+3\lambda \\ 1+\lambda \end{pmatrix}, \quad x^1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, d^1 = \begin{pmatrix} 3 \\ 1 \end{pmatrix},$$

$$\phi(\lambda) = f(x^1 + \lambda d^1) = f(1+3\lambda, 1+\lambda)$$

$$= (1+3\lambda)^2 + 2(1+\lambda)^2 - 2(1+3\lambda)(1+\lambda) - 4(1+3\lambda)$$

令 $0 = \phi'(\lambda) = 6(1+3\lambda) + 4(1+\lambda) - 6(1+\lambda) - 2(1+3\lambda) - 12$

得 $\lambda_1 = 1$, $x^2 = x^1 + \lambda_1 d^1 = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$,

$$\nabla f(x^2) = \begin{pmatrix} 2x_1 - 2x_2 - 4 \\ -2x_1 + 4x_2 \end{pmatrix} \Big|_{x=x^2} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

故得到极小点 $x^* = x^2 = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$.

一步即达到最优解

利用阻尼Newton法求 n 元正定二次函数的极小点，从任意初始点出发，一步迭代即可达到极小点。

设 $f(x) = 1/2x^T Ax + b^T x + c$, 其中 A_{nn} 正定, $b \in R^n, c \in R$.
 f 的极小点是 f 等值面的中心, $x^* = -A^{-1}b$.

下面用阻尼Newton法求解 f 的极小点:

$$\forall x^1 \in R^n, \nabla f(x^1) = Ax^1 + b, \nabla^2 f(x^1) = A,$$

$$d^1 = -(\nabla^2 f(x^1))^{-1} \nabla f(x^1) = -A^{-1}g_1,$$

利用阻尼Newton法求 n 元正定二次函数的极小点，从任意初始点出发，一步迭代即可达到极小点。

$$d^1 = -A^{-1}g_1,$$

$$\text{最佳步长 } \lambda_i = \arg \min f(x^1 + \lambda_i d^1) := \arg \min \phi(\lambda)$$

$$\text{由 } \phi'(\lambda_i) = (\nabla f(x^1 + \lambda_i d^1))^T d^1 = 0,$$

$$0 = (A(x^1 + \lambda_i d^1) + b)^T d^1 = (g_1 + \lambda_i A d^1)^T d^1,$$

故

$$\lambda_i = -\frac{g_1^T d^1}{(d^1)^T A d^1} = -\frac{g_1^T d^1}{(d^1)^T A (-A^{-1} g_1)} = \frac{g_1^T d^1}{(d^1)^T g_1} = 1,$$

$$x^2 = x^1 + \lambda_i d^1 = x^1 + 1 * (-A^{-1} g_1) = x^1 - A^{-1}(Ax^1 + b) = -A^{-1}b.$$

一步即达到最优解

利用阻尼Newton法求 n 元正定二次函数的极小点，从任意初始点出发，一步迭代即可达到极小点。

阻尼Newton法具有二次终止性

二次终止性（二次收敛性）

从任意初始点出发，经有限次迭代总可以达到 n 元正定二次函数的极小点，称这样的算法具有二次终止性。

Newton法的进一步修正

阻尼Newton法改进了Newton法，但还是存在缺点：

(2) 每次迭代都要计算Hesse矩阵，计算量大；

(3) $(\nabla^2 f(x^k))^{-1}$ 可能不存在，即使存在，也未必正定，因而

牛顿方向不一定是下降方向。

$$d^k = -(\nabla^2 f(x^k))^{-1} \nabla f(x^k)$$

缺点(3)的改进方法之一：

当 d^k 为函数上升方向时，可向其负方向搜索，

但可能出现在 d^k 上函数值都不变化的情况。

Newton法的改进---针对缺点(2)每次计算Hesse矩阵

(1) 为减小工作量，取 m (正整数)，使每 m 次迭代使用同一个Hesse阵，迭代公式变为：

$$x^{k_m+j+1} = x^{k_m+j} - (\nabla^2 f(x^{k_m}))^{-1} \nabla f(x^{k_m+j}),$$

$$j=0,1,\dots,m-1, k=0,1,2,\dots$$

特点：收敛速度随 m 的增大而下降。

$m=1$ 时即Newton法， $m \rightarrow \infty$ 线性收敛。

牛顿法还有其它的修正方式

Newton法的改进---针对缺点(3)非正定和奇异的情况

(2) Goldstein-Price方法(G-P法)：

$$\text{搜索方向: } d^k = \begin{cases} -(\nabla^2 f(x^k))^{-1} \nabla f(x^k), & \nabla^2 f(x^k) \text{ 正定} \\ -\nabla f(x^k), & \text{否则} \end{cases}$$

步长：Armijo-Goldstein准则求 λ_k ,

$$\begin{cases} f(x^k + \lambda_k d^k) \leq f(x^k) + \delta \lambda_k (\nabla f(x^k))^T d^k \\ f(x^k + \lambda_k d^k) \geq f(x^k) + (1-\delta) \lambda_k (\nabla f(x^k))^T d^k \end{cases}, \delta \in \left(0, \frac{1}{2}\right),$$

特点：在一定条件下，G-P法全局收敛。

但当 $\nabla^2 f(x^k)$ 非正定情况较多时，收敛速度降为接近线性。

Newton法的改进---针对缺点(3)非正定的情况

(3) Levenberg-Marguardt法 (L-M法) :

主要思想：

找到尽可能小的 $\mu > 0$ 使 $\nabla^2 f(x^k) + \mu I$ 正定，

其中 I 为单位矩阵，

用 $\nabla^2 f(x^k) + \mu I$ 取代 $\nabla^2 f(x^k)$ 进行迭代。

特点：全局二阶收敛。

作业 P 99 4.3

4.3 迭代14次得到近似解 $(-0.6344, -0.0032)^T$ ，
近似最优值为 -0.4724。

共轭方向法和共轭梯度法

最速下降法，计算步骤简单，但收敛速度慢。

Newton法和阻尼Newton法收敛速度快，但需要计算Hesse矩阵及其逆矩阵，计算量、存储量很大。

需要寻找一种好的算法，这种算法能够兼有这两种方法的优点，又能克服它们的缺点，即收敛速度快同时计算简单。

这就是要讨论的共轭方向法和共轭梯度法。

共轭方向法和共轭梯度法

共轭方向法和共轭梯度法：收敛速度快同时计算简单。

共轭方向法计算效果好，应用广泛；

共轭梯度法是最著名的共轭方向法。

共轭方向法---共轭方向及其性质

定义 设 $A_{n \times n}$ 是对称正定矩阵，给定非0向量 $p^1, p^2, \dots, p^m \in R^n$,

(1) 如果 $(p^1)^T A p^2 = 0$, 则称 p^1 和 p^2 是 A -共轭(或 A -正交)的。

(2) 如果 $(p^i)^T A p^j = 0 (\forall i \neq j)$, 则称 p^1, p^2, \dots, p^m 是 A -共轭(或 A -正交)向量组，也称它们是一组 A -共轭方向。

注：

若 $A=I$, $(p^1)^T A p^2 = (p^1)^T p^2 = 0$, 则 p^1 与 p^2 是正交的。

共轭是正交的推广；

共轭向量组是正交向量组的推广。

共轭方向法---共轭方向及其性质

假设 f 是 n 元正定二次函数 $f(x) = \frac{1}{2} x^T A x + b^T x + c$, A 正定，

二维情况 ($n=2$)

任取初始点 x^1 , 沿某个下降方向 d^1 作精确一维搜索, 得

$$x^2 = x^1 + \lambda_1 d^1.$$

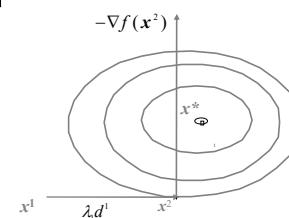
由精确一维搜索的性质, 可知

$$(\nabla f(x^2))^T d^1 = 0.$$

如果按最速下降法, 选取

$$d^2 = -\nabla f(x^2),$$

则将发生锯齿现象。



共轭方向法---共轭方向及其性质

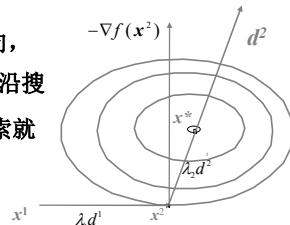
二维情况 ($n=2$)

任取初始点 x^1 , 沿某个下降方向 d^1 作精确一维搜索, 得
 $x^2 = x^1 + \lambda_1 d^1, \quad (\nabla f(x^2))^T d^1 = 0.$

如果希望下次迭代就得到最优解, $d^2=?$

如果能够选定这样的搜索方向,
 那么对于二元二次函数只需依次沿搜
 索方向 d^1, d^2 进行次精确一维搜索就
 可以求到极小点 x^* , 即

$$x^* = x^2 + \lambda_2 d^2.$$



共轭方向法---共轭方向及其性质

$$x^* = x^2 + \lambda_2 d^2.$$

x^* 是 f 的极小点, 故 x^* 是 f 的驻点,
 $\nabla f(x^*) = Ax^* + b = 0,$

$$0 = \nabla f(x^*) = Ax^* + b = A(x^2 + \lambda_2 d^2) + b = (Ax^2 + b) + \lambda_2 Ad^2 = \nabla f(x^2) + \lambda_2 Ad^2$$

将等式两边同时左乘 $(d^1)^T$ 得:

$$0 = (d^1)^T \nabla f(x^2) + \lambda_2 (d^1)^T Ad^2 = 0 + \lambda_2 (d^1)^T Ad^2,$$

即 $(d^1)^T Ad^2 = 0.$

两次迭代要得到二元二次函数的极小点, d^1 必须满足的条件是:

$(d^1)^T Ad^2 = 0,$
 搜索方向 d^1 和 d^2 是 A 共轭的。 d^1 是某个下降方向

共轭方向法---共轭方向的性质

性质1 R^n 中与 n 个线性无关的向量都正交的一定是零向量。

性质2 R^n 中 A 共轭的向量组 p^1, p^2, \dots, p^m 是线性无关的。

性质3 R^n 中互相共轭的向量个数不超过 n 。

性质4 给定 n 元函数 $f(x) = 1/2x^T Ax + b^T x + c$, $A = A^T$ 正定, 设 n 维向量组 p^1, p^2, \dots, p^n 是 A 共轭向量组, 从任意点 x^1 出发, 依次以 p^1, p^2, \dots, p^n 为搜索方向进行精确一维搜索, 则

- (1) $\nabla f(x^{k+1})$ 与 p^1, p^2, \dots, p^k ($k=1, 2, \dots, n$) 正交;
- (2) 最多 n 次迭代必达到 n 元二次函数 f 的极小点。

共轭方向法---共轭方向及其性质

性质1 R^n 中与 n 个线性无关的向量都正交的一定是零向量。

证明: 给定 R^n 中的向量 p^1, p^2, \dots, p^n, d , 若 p^1, p^2, \dots, p^n 线性无关, 且 d 与 p^1, p^2, \dots, p^n 正交, 证 $d=0$.

p^1, p^2, \dots, p^n 线性无关, 故 p^1, p^2, \dots, p^n 可作为 R^n 的一组基, 故 d 可由 p^1, p^2, \dots, p^n 线性表出, 即存在一组实数 $\alpha_1, \alpha_2, \dots, \alpha_n$, s.t.

$$d = \alpha_1 p^1 + \alpha_2 p^2 + \dots + \alpha_n p^n.$$

$$\begin{aligned} d^T d &= d^T (\alpha_1 p^1 + \alpha_2 p^2 + \dots + \alpha_n p^n) = \alpha_1 d^T p^1 + \alpha_2 d^T p^2 + \dots + \alpha_n d^T p^n \\ &= \alpha_1 \cdot 0 + \alpha_2 \cdot 0 + \dots + \alpha_n \cdot 0 = 0, \end{aligned}$$

故 $d=0$.

共轭方向法---共轭方向及其性质

性质2 R^n 中 A 共轭的向量组 p^1, p^2, \dots, p^m 是线性无关的。

证明 假设 $\alpha_1 p^1 + \alpha_2 p^2 + \dots + \alpha_m p^m = 0$, 要证 p^1, p^2, \dots, p^m 线性无关,
只需证明 $\alpha_1 = \alpha_2 = \dots = \alpha_m = 0$.

因为 p^1, p^2, \dots, p^m 是 A 共轭向量组, 两边同乘 $(p^k)^T A, \forall k=1, \dots, m$,

$$\begin{aligned} 0 &= (p^k)^T A (\alpha_1 p^1 + \alpha_2 p^2 + \dots + \alpha_m p^m) \\ &= 0 + 0 + \dots + \alpha_k (p^k)^T A p^k + \dots + 0 \\ &= \alpha_k (p^k)^T A p^k, \end{aligned}$$

因为 A 正定, $p^k \neq 0$, 所以 $(p^k)^T A p^k > 0$, 故 $\alpha_k = 0, \forall k=1, \dots, m$,
得证。

共轭方向法---共轭方向及其性质

性质3 R^n 中互相共轭的向量个数不超过 n .

证明 利用**性质2**即可。

性质2 R^n 中 A 共轭的向量组 p^1, p^2, \dots, p^m 是线性无关的。

R^n 中线性无关的非零向量最多有 n 个。

共轭方向法---共轭方向的性质

性质4 给定 n 元函数 $f(x) = 1/2x^T Ax + b^T x + c$, $A = A^T$ 正定, 设 n 维
向量组 p^1, p^2, \dots, p^n 是 A 共轭向量组, 从任意点 x^l 出发,
依次以 p^1, p^2, \dots, p^n 为搜索方向进行精确一维搜索, 则
(1) $\nabla f(x^{l+1})$ 与 p^1, p^2, \dots, p^l ($l=1, 2, \dots, n$)正交;
(2) 最多 n 次迭代必达到 n 元二次函数 f 的极小点。

共轭方向法---共轭方向及其性质

性质4 中(1) $\nabla f(x^{l+1})$ 与 p^1, p^2, \dots, p^l ($l=1, 2, \dots, n$) 正交;

证明 λ_l 是按照精确一维搜索得到的, 故 $(\nabla f(x^{l+1}))^T p^l = 0$.

下证 $\nabla f(x^{l+1})^T p^i = 0, i=1, 2, \dots, l-1$.

$$\begin{aligned} f(x) &= \frac{1}{2} x^T A x + b^T x + c, \quad \nabla f(x) = Ax + b, \\ \nabla f(x^{l+1}) &= Ax^{l+1} + b = A(x^l + \lambda_l p^l) + b = (Ax^l + b) + \lambda_l A p^l \\ &= \nabla f(x^l) + \lambda_l A p^l \\ \nabla f(x^{l+1}) &= \nabla f(x^l) + \lambda_l A p^l = \nabla f(x^{l-1}) + \lambda_{l-1} A p^{l-1} + \lambda_l A p^l \\ &= \dots \\ &= \nabla f(x^{l+1}) + \lambda_{l+1} A p^{l+1} + \dots + \lambda_{l-1} A p^{l-1} + \lambda_l A p^l, \quad i=1, 2, \dots, l-1, \end{aligned}$$

共轭方向法---共轭方向及其性质

性质4中(1) $\nabla f(x^{i+1})$ 与 p^1, p^2, \dots, p^l ($l=1, 2, \dots, n$)正交；

$$\begin{aligned}\nabla f(x^{i+1}) &= \nabla f(x^{i+1}) + \lambda_{i+1} A p^{i+1} + \dots + \lambda_{l-1} A p^{l-1} + \lambda_l A p^l, \\ (\nabla f(x^{i+1}))^T p^i &= (\nabla f(x^{i+1}))^T p^i + \lambda_{i+1} (A p^{i+1})^T p^i \\ &\quad + \dots + \lambda_{l-1} (A p^{l-1})^T p^i + \lambda_l (A p^l)^T p^i \\ &= \nabla f(x^{i+1})^T p^i + \lambda_{i+1} (p^{i+1})^T A p^i \\ &\quad + \dots + \lambda_{l-1} (p^{l-1})^T A p^i + \lambda_l (p^l)^T A p^i \\ &= 0,\end{aligned}$$

故 $\nabla f(x^{i+1})$ 与 p^1, p^2, \dots, p^l ($l=1, 2, \dots, n$)正交。

P^1, P^2, \dots, P^n 是 A 共轭向量组

共轭方向法---共轭方向及其性质

性质4中(2) 最多 n 次迭代必达到二次函数 f 的极小点。

证明 假设 $\nabla f(x^1), \nabla f(x^2), \dots, \nabla f(x^n)$ 都不是 0，下证

$$\nabla f(x^{n+1}) = 0.$$

利用性质4(1)的结果， $\nabla f(x^{n+1})$ 与 A 共轭向量组 P^1, P^2, \dots, P^n 都正交，由性质2和性质1可知， $\nabla f(x^{n+1}) = 0$.

性质2 R^n 中 A 共轭的向量组 p^1, p^2, \dots, p^m 是线性无关的。

性质4(1) $\nabla f(x^{i+1})$ 与 p^1, p^2, \dots, p^l ($l=1, 2, \dots, n$) 正交；

性质1 R^n 中与 n 个线性无关的向量都正交的一定是零向量。

共轭方向法---共轭方向的性质

性质4 给定 n 元函数 $f(x) = 1/2 x^T A x + b^T x + c$, $A = A^T$ 正定, 设 n 维向量组 p^1, p^2, \dots, p^n

是 A 共轭向量组, 从任意点 x^1 出发, 相继以 p^1, p^2, \dots, p^n 为搜索方向进行精确一维搜索, 则

(1) $\nabla f(x^{i+1})$ 与 p^1, p^2, \dots, p^l ($l=1, 2, \dots, n$) 正交;

(2) 最多 n 次迭代必达到 n 元二次函数 f 的极小点。

在迭代法中, 若取搜索方向是共轭方向, 得到的方法称为共轭方向法。

由性质4可知, 若能找到一组 A 共轭向量 p^1, p^2, \dots, p^n ,

则结合最速下降法和Newton法优点的算法就找到了, 就是共轭方向法。

这个算法具有二次收敛性。

怎么选取共轭方向?

定义 一个算法若能在有限步内求得正定二次函数的极

小点, 则称该算法具有二次收敛性(又称二次终止性)。

共轭方向的生成与共轭梯度法

共轭方向的选取有很大任意性, 共轭方向不同的选取方法对应着不同的共轭方向法。

作为一种迭代算法, 自然希望共轭方向能在迭代过程中逐次生成。

下面先以正定二次函数为例, 介绍一种产生共轭方向的方法, 再将这种方法推广到非二次函数上。

这种方法中的每一个共轭向量都依赖于迭代点处的负梯度, 因此称为共轭梯度法, 它是共轭方向法中的一种。

共轭梯度法

$$\text{令 } f(x) = \frac{1}{2}x^T Ax + b^T x + c, A = A^T \text{ 正定}$$

(1) 从任取初始点 x^1 出发, 沿负梯度方向进行精确一维搜索:

$$p^1 = -\nabla f(x^1), \quad x^2 = x^1 + \alpha_1 p^1,$$

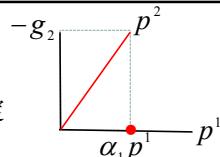
(2) 若 $\nabla f(x^2) = 0$, 停止, 否则在 $-\nabla f(x^2)$ 和 p^1 张成的

正交锥中找一个向量 p^2 , 即令 $p^2 = -\nabla f(x^2) + \alpha_1 p^1$

使得 p^1 与 p^2 共轭, 即 $(p^2)^T A p^1 = 0$. $\alpha_1 = ?$

由 $(p^2)^T A p^1 = 0 = (-\nabla f(x^2) + \alpha_1 p^1)^T A p^1$, 可得

$$\alpha_1 = \frac{\nabla f(x^2)^T A p^1}{(p^1)^T A p^1}$$



共轭梯度法

(3) 在 x^2 处沿 p^2 方向进行精确一维搜索,

$$x^3 = x^2 + \lambda_2 p^2,$$

(4) 以此类推, $x^4, x^5, \dots, x^k, x^{k+1}$,

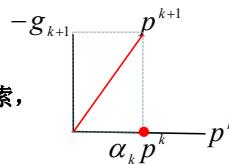
(5) 若 $\nabla f(x^{k+1}) = 0$, 停止, 否则在 $-\nabla f(x^{k+1})$ 和 p^k 张

成的正交锥中找一个向量 p^{k+1} , 即令 $p^{k+1} = -\nabla f(x^{k+1}) + \alpha_k p^k$

使得 p^{k+1} 与 p^k 共轭, 即 $(p^{k+1})^T A p^k = 0$. $\alpha_k = ?$

由 $(p^{k+1})^T A p^k = 0 = (-\nabla f(x^{k+1}) + \alpha_k p^k)^T A p^k$ 可得

$$\alpha_k = \frac{\nabla f(x^{k+1})^T A p^k}{(p^k)^T A p^k}$$



共轭梯度法

如此便构造了一组向量 p^1, p^2, \dots, p^n ,

$$p^1 = -\nabla f(x^1), \quad \text{相邻两个向量是共轭的}$$

$$p^{k+1} = -\nabla f(x^{k+1}) + \alpha_k p^k, k=1, 2, \dots, n-1,$$

$$\alpha_k = \frac{\nabla f(x^{k+1})^T A p^k}{(p^k)^T A p^k},$$

实际上, 这组向量 p^1, p^2, \dots, p^n 是一个 A 共轭向量组。

共轭梯度法

定理1 设向量组 p^1, p^2, \dots, p^n 是由上述方法产生的向量组, 向量组 g_1, g_2, \dots, g_n 是由各点的梯度生成的向量组 ($g_k = \nabla f(x^k)$), 则

(1) g_1, g_2, \dots, g_n 是正交向量组;

(2) p^1, p^2, \dots, p^n 是 A 共轭向量组。

共轭梯度法

定理1 设向量组 p^1, p^2, \dots, p^n 是由上述方法产生的向量组, 向量组 g_1, g_2, \dots, g_n 是由各点的梯度生成的向量组 ($g_k = \nabla f(x^k)$), 则

- (1) g_1, g_2, \dots, g_n 是正交向量组;
- (2) p^1, p^2, \dots, p^n 是 A 共轭向量组。

证明 归纳法:

(i) $n=2$ 由 p^i 的构造过程知, p^1, p^2 是 A 共轭的, 即 $(p^2)^T A p^1 = 0$, 结论(2)成立;

利用精确一维搜索的性质知, $(g_2)^T p^1 = 0$, 而 $p^1 = -g_1$, 故 $(g_2)^T g_1 = 0$, 结论(1)成立。

(ii) 假设 $n=k$ 时, 结论(1)(2)成立, 下证 $n=k+1$ 时结论仍成立。

由假设可知, 要证明 $n=k+1$ 时结论成立, 只需证明

g_{k+1} 与 g_1, g_2, \dots, g_k 正交, p^{k+1} 与 p^1, p^2, \dots, p^k 共轭。

(a) 证明 g_{k+1} 与 g_1, g_2, \dots, g_k 正交;

$$\text{因为 } p^i = \begin{cases} -g_i, & i=1, \\ -g_i + \alpha_{i-1} p^{i-1}, & i=2, \dots, n, \end{cases}$$

$$\text{所以 } (g_{k+1})^T g_i = \begin{cases} (g_{k+1})^T (-p^i), & i=1, \\ (g_{k+1})^T (-p^i + \alpha_{i-1} p^{i-1}), & i=2, \dots, k, \end{cases} = 0,$$

p^1, p^2, \dots, p^k 是 A 共轭向量组, 利用性质4(1)可知,

性质4 给定 n 元函数 $f(x) = 1/2 x^T A x + b^T x + c$, A 为 $A^T A$ 正定, 设 n 维非零向量组 p^1, p^2, \dots, p^n 是 A 共轭向量组, 从任意点 x^0 出发, 相继以 p^1, p^2, \dots, p^n 为搜索方向进行精确一维搜索, 则 结论(i) 成立, p^n 进而结论(ii) 成立;

(b) 证明 p^{k+1} 与 p^1, p^2, \dots, p^k 是 A 共轭的;

由 p^i 的构造过程知, p^{k+1} 与 p^k 是 A 共轭的;

下证 p^{k+1} 与 p^1, p^2, \dots, p^{k-1} 是 A 共轭的;

$$\begin{aligned} (p^{k+1})^T A p^i &= (-g_{k+1} + \alpha_k p^k)^T A p^i \quad (i=1, 2, \dots, k-1) \\ &= -(g_{k+1})^T A p^i \quad (p^k)^T A p^i = 0, \quad i=1, 2, \dots, k-1 \end{aligned}$$

$$g_{i+1} - g_i = Ax^{i+1} + b - g_i = A(x^i + \lambda_i p^i) + b - g_i = \lambda_i A p^i$$

$$\begin{aligned} \therefore (p^{k+1})^T A p^i &= -(g_{k+1})^T A p^i = - (g_{k+1})^T \frac{g_{i+1} - g_i}{\lambda_i} \\ &= -1/\lambda_i (g_{k+1})^T (g_{i+1} - g_i) \quad (g_{k+1})^T g_i = 0, \quad i=1, 2, \dots, k \\ &= 0 \end{aligned}$$

结论(b)成立, 进而结论(2)成立。

共轭梯度法

定理1 设向量组 p^1, p^2, \dots, p^n 是由上述方法产生的向量组,

向量组 g_1, g_2, \dots, g_n 是由各点的梯度生成的向量组

$(g_k = \nabla f(x^k))$, 则

- (1) g_1, g_2, \dots, g_n 是正交向量组;

- (2) p^1, p^2, \dots, p^n 是 A 共轭向量组。

注 为保证方向的共轭性, 初始方向取负梯度方向。

共轭梯度法--算例 初始方向为下降方向, 但不是负梯度方向

例 用共轭方向法求下列问题

$$\min f(x) = x_1^2 + \frac{x_2^2}{2} + \frac{x_3^2}{2}, \text{ 已知初始点 } x^1 = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}, p^1 = \begin{pmatrix} 1 \\ -2 \\ 0 \end{pmatrix}, p^1 \neq -g_1,$$

解: 第一次迭代: 沿 p^1 方向进行精确一维搜索, 得 $\lambda_1 = 2/3$,

$$x^2 = x^1 + \lambda_1 p^1 = \left(\frac{1}{3}, -\frac{1}{3}, 1 \right)^T, g_2 = \nabla f(x^2) = \left(\frac{2}{3}, -\frac{1}{3}, 1 \right)^T,$$

第二次迭代:

$$\alpha_1 = \frac{g_2^T A p^1}{(p^1)^T A p^1} = -\left(\frac{2}{3}\right)/6 = -\frac{1}{9}, \quad g_1 = (2, 1, 1)^T, \\ p^2 = -g_2 + \alpha_1 p^1 = \left(-\frac{5}{9}, \frac{5}{9}, -1\right)^T.$$

共轭梯度法--算例

沿 p^2 方向进行精确一维搜索, 得 $\lambda_2 = 21/26$,

$$x^3 = x^2 + \lambda_2 p^2 = \left(-\frac{3}{26}, \frac{3}{26}, \frac{5}{26}\right)^T, g_3 = \left(-\frac{3}{13}, \frac{3}{26}, \frac{5}{26}\right)^T,$$

第三次迭代:

$$\alpha_2 = \frac{g_3^T A p^2}{(p^2)^T A p^2} = \frac{45}{676},$$

$$p^3 = -g_3 + \alpha_2 p^2 = \frac{1}{676}(131, -53, -175)^T.$$

沿 p^3 方向进行精确一维搜索, 得 $\lambda_3 = 910/1303$,

$$x^4 = x^3 + \lambda_3 p^3 = \frac{1}{1303}(26, 79, 15)^T \neq (0, 0, 0)^T,$$

3次迭代没有到达3元二次函数的极小点 $(0, 0, 0)^T$, 为什么?

共轭梯度法--算例 p^1, p^2 与 p^3 是不是 A 共轭向量组?

$$(p^1)^T A p^2 = (-1, -2, 0) diag(2, 1, 1) \begin{pmatrix} -\frac{5}{9}, \frac{5}{9}, -1 \end{pmatrix}^T = 0,$$

$$(p^3)^T A p^2 = \frac{1}{676}(131, -53, -175) diag \begin{pmatrix} 1 & \frac{1}{2} & \frac{1}{2} \end{pmatrix} \begin{pmatrix} x_1^2 & \frac{x_2^2}{2} & \frac{x_3^2}{2} \end{pmatrix} \begin{pmatrix} -\frac{5}{9}, \frac{5}{9}, -1 \end{pmatrix}^T = 0,$$

$$(p^3)^T A p^1 = A = \nabla^2 f(x) = diag(2, 1, 1) \\ = \frac{1}{676}(131, -53, -175) diag(2, 1, 1)(-1, -2, 0)^T = -\frac{3}{13},$$

$$p^1, p^2 \text{与} p^3 \text{不是} A \text{的共轭向量组. } p^1 = \begin{pmatrix} 1 \\ -2 \\ 0 \end{pmatrix},$$

$$p^3 = \frac{1}{676}(131, -53, -175)^T, A = diag(2, 1, 1)$$

共轭梯度法

每一个搜索方向都依赖迭代点处的负梯度, 对应的算法称为共轭梯度法。

$$\begin{cases} p^1 = -\nabla f(x^1), \\ p^{k+1} = -\nabla f(x^{k+1}) + \alpha_k p^k, k = 1, 2, \dots, n-1, \\ \alpha_k = \frac{\nabla f(x^{k+1})^T A p^k}{(p^k)^T A p^k}. \end{cases} \quad (*)$$

p^1, p^2, \dots, p^n 是一个 A 共轭向量组

性质4 给定 n 元函数 $f(x) = 1/2 x^T A x + b^T x + c$, $A = A^T$ 正定, 设 n 维非零

向量组 p^1, p^2, \dots, p^n 是 A 共轭向量组, 从任意点 x^1 出发, 相继以 p^1, p^2, \dots, p^n 为搜索方向进行精确一维搜索, 则

- (1) $\nabla f(x^{l+1})$ 与 p^1, p^2, \dots, p^l ($l=1, 2, \dots, n$)正交;
- (2) 最多 n 次迭代必达到正定二次函数 f 的极小点。

共轭梯度法

针对 “ $f(x)=\frac{1}{2}x^T Ax + b^T x + c$, $A=A^T$ 正定, 最多 n 次迭代达到极小点” 找到了一组共轭方向:

$$\begin{cases} p^1 = -\nabla f(x^1), \\ p^{k+1} = -\nabla f(x^{k+1}) + \alpha_k p^k, k=1,2,\dots,n-1, \\ \alpha_k = \frac{(\nabla f(x^{k+1}))^T A p^k}{(p^k)^T A p^k}. \end{cases} \quad (*)$$

在正定二次函数的前提下, 将 α_k 变形

能否将 α_k 中的 A 去掉?

怎么解决呢?

针对一般函数, 将这组方向进行推广,

直接对(*)式推广: $A \rightarrow \nabla^2 f(x^{k+1})$

存在问题: 计算量、存储量都很大

共轭梯度法

定理2 设 $f(x) = \frac{1}{2}x^T Ax + b^T x + c$, $A = A^T$ 正定, p^1, p^2, \dots, p^n 是由上述方法构造的 A 共轭向量组, $g_k = \nabla f(x^k)$, 利用前面所得的公式, 得到几个等价的计算公式:

$$(1) \alpha_k = \frac{(\nabla f(x^{k+1}))^T A p^k}{(p^k)^T A p^k} = \frac{(g_{k+1})^T A p^k}{(p^k)^T A p^k} \quad (\text{Daniel, 1967})$$

$$(2) \alpha_k = \frac{g_{k+1}^T g_k}{(g_k^T g_k)^T (g_{k+1} - g_k)} = \frac{A(x^k + \lambda_k p^k) + b - g_k}{(g_k^T g_k)^T (g_{k+1} - g_k)} = \lambda_k A p^k \quad (\text{Sorenson-Wolfe, 1972})$$

$$(2) \alpha_k = \frac{(g_{k+1})^T (g_{k+1} - g_k)}{(p^k)^T (g_{k+1} - g_k)} \quad (\text{Sorenson-Wolfe, 1972})$$

利用定理1, 可知 g_1, g_2, \dots, g_n 是正交向量组, 因此(2)

$$(3) \alpha_k = 0; \quad (4) \frac{(g_{k+1})^T g_k}{(p^k)^T g_k} = 0 \quad (\text{Dixon-Myers, 1972})$$

$$(3) \alpha_k = -\frac{(g_{k+1})^T g_{k+1}}{(p^k)^T g_k} \quad (\text{Dixon-Myers, 1972})$$

共轭梯度法

$$(3) \alpha_k = -\frac{(g_{k+1})^T g_{k+1}}{(p^k)^T g_k} \quad (\text{Dixon-Myers, 1972})$$

在(3)中, 由 $p^k = -g_k + \alpha_{k-1} p^{k-1}$,

$$(4) \alpha_k = \frac{\|g_k\|^2}{\|g_{k+1}\|^2} \quad (\text{Fletcher-Reeves, 1964})$$

$$(4) \alpha_k = \frac{\|g_{k+1}\|^2}{\|g_k\|^2} \quad (\text{Fletcher-Reeves, 1964})$$

$$(5) \alpha_k = \frac{(g_{k+1})^T (g_{k+1} - g_k)}{(g_k^T g_k)^T (g_{k+1} - g_k)} \quad (\text{Sorenson-Wolfe, 1972})$$

$$(2)+(p^k)^T (g_{k+1} - g_k) = -(p^k)^T g_k = -(-g_k + \alpha_{k-1} p^{k-1})^T g_k = (g_k)^T g_k$$

$$(5) \alpha_k = \frac{(g_{k+1})^T (g_{k+1} - g_k)}{(g_k)^T g_k} \quad (\text{Polyak-Polak-Ribiere, 1969})$$

$$(1) \alpha_k = \frac{(\nabla f(x^{k+1}))^T A p^k}{(p^k)^T A p^k} = \frac{(g_{k+1})^T A p^k}{(p^k)^T A p^k} \quad (\text{Daniel, 1967})$$

$$(2) \alpha_k = \frac{(g_{k+1})^T (g_{k+1} - g_k)}{(p^k)^T (g_{k+1} - g_k)} \quad (\text{Sorenson-Wolfe, 1972})$$

$$(3) \alpha_k = -\frac{(g_{k+1})^T g_{k+1}}{(p^k)^T g_k} \quad (\text{Dixon-Myers, 1972})$$

$$(4) \alpha_k = \frac{\|g_{k+1}\|^2}{\|g_k\|^2} \quad (\text{Fletcher-Reeves, 1964})$$

$$(5) \alpha_k = \frac{(g_{k+1})^T (g_{k+1} - g_k)}{(g_k)^T g_k} \quad (\text{Polyak-Polak-Ribiere, 1969})$$

对于正定二次函数, 上面得到的5个计算公式是等价的;

这5种共轭梯度法也是完全等价的;

对于非二次函数, 产生的搜索方向不再相同,

常利用公式(2)-(5), 通常不用公式(1) ((1)中含有Hesse矩阵).

FR共轭梯度法--算法步骤

- 步骤1 选定初始点 x^1 .
- 步骤2 如果 $\|g_1\| \leq \varepsilon$, 停止, 得到近似驻点 x^1 , 否则转步骤3。
- 步骤3 取 $p^1 = -g_1, k=1$.
- 步骤4 精确一维搜索找最佳步长 λ_k , 令 $x^{k+1} = x^k + \lambda_k p^k$.
- 步骤5 如果 $\|g_{k+1}\| \leq \varepsilon$, 停止, 得到近似驻点 x^{k+1} , 否则转步骤6。
- 步骤6 如果 $k=n$, 令 $x^1=x^{k+1}, p^1=-g_{k+1}, k=1$, 转步骤4;
否则转步骤7。
- 步骤7 计算 $\alpha_k = \frac{\|g_{k+1}\|^2}{\|g_k\|^2}, p^{k+1} = -g_{k+1} + \alpha_k p^k, k=k+1$, 转步骤4。

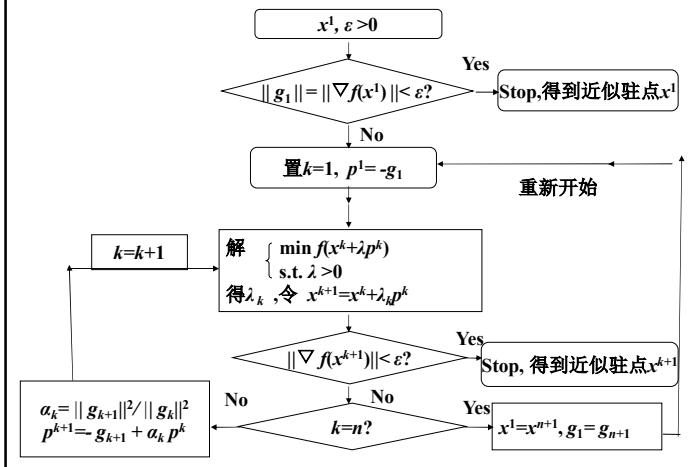
FR共轭梯度法--算法步骤

- 步骤4 精确一维搜索找最佳步长 λ_k , 令 $x^{k+1} = x^k + \lambda_k p^k$.
- 步骤5 如果 $\|g_{k+1}\| \leq \varepsilon$, 停止, 得到近似驻点 x^{k+1} , 否则转步骤6。
- 步骤6 如果 $k=n$, 令 $x^1=x^{k+1}, p^1=-g_{k+1}, k=1$, 转步骤4;
否则转步骤7。
- 步骤7 计算 $\alpha_k = \frac{\|g_{k+1}\|^2}{\|g_k\|^2}, p^{k+1} = -g_{k+1} + \alpha_k p^k, k=k+1$, 转步骤4。

误差可能会使n步迭代得不到正定二次函数的极小点。

R^n 中共轭方向最多有n个, n步后构造的搜索方向不再是共轭的, 会降低收敛速度,
步骤6: 重新开始技术: x^{n+1} 作为新的 x^1

FR共轭梯度法--算法框图



FR共轭梯度法--算例

例 用FR共轭梯度法求 $\min f(x) = x_1^2 + 2x_2^2 - 4x_1 - 2x_1x_2$,
取 $x^1 = (1, 1)^T, \varepsilon = 10^{-2}$. $x^* = (4, 2)^T$.

解: 1) 第一次迭代: 沿负梯度方向搜寻
计算初始点处的梯度

$$g_1 = \nabla f(x^1) = \begin{pmatrix} 2x_1 - 2x_2 - 4 \\ 4x_2 - 2x_1 \end{pmatrix} \Big|_{x=x^1} = \begin{pmatrix} -4 \\ 2 \end{pmatrix},$$

$$p^1 = -g_1 = \begin{pmatrix} 4 \\ -2 \end{pmatrix} \quad x^1 + \lambda p^1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \lambda \begin{pmatrix} 4 \\ -2 \end{pmatrix} = \begin{pmatrix} 1+4\lambda \\ 1-2\lambda \end{pmatrix}$$

FR共轭梯度法--算例

$$x^1 + \lambda p^1 = \begin{pmatrix} 1+4\lambda \\ 1-2\lambda \end{pmatrix}$$

精确一维搜索求最佳步长,

$$\phi(\lambda) = f(x^1 + \lambda p^1) = f(1+4\lambda, 1-2\lambda) = 40\lambda^2 - 20\lambda - 3,$$

$$\text{令 } 0 = \phi'(\lambda) = 80\lambda - 20,$$

$$\text{得 } \lambda_1 = \frac{1}{4}, \quad x^2 = x^1 + \lambda_1 p^1 = \begin{pmatrix} 2 \\ \frac{1}{2} \end{pmatrix},$$

$$g_2 = \nabla f(x^2) = \begin{pmatrix} -1 \\ -2 \end{pmatrix}, \quad \|g_2\| = \sqrt{5} > \varepsilon,$$

继续迭代;

FR共轭梯度法--算例

$$g_1 = \begin{pmatrix} -4 \\ 2 \end{pmatrix}, \quad g_2 = \begin{pmatrix} -1 \\ -2 \end{pmatrix},$$

2) 第二次迭代

$$\alpha_1 = \frac{\|g_2\|^2}{\|g_1\|^2} = \frac{5}{20} = \frac{1}{4},$$

$$p^2 = -g_2 + \alpha_1 p^1 = \begin{pmatrix} 2 \\ \frac{3}{2} \end{pmatrix}, \quad x^2 + \lambda p^2 = \begin{pmatrix} 2 \\ \frac{1}{2} \end{pmatrix} + \lambda \begin{pmatrix} 2 \\ \frac{3}{2} \end{pmatrix} = \begin{pmatrix} 2+2\lambda \\ \frac{1}{2} + \frac{3}{2}\lambda \end{pmatrix},$$

精确一维搜索求最佳步长,

$$\begin{aligned} \phi(\lambda) &= f(x^2 + \lambda p^2) = f(2+2\lambda, \frac{1}{2} + \frac{3}{2}\lambda) \\ &= (2+2\lambda)^2 + 2(\frac{1}{2} + \frac{3}{2}\lambda)^2 - 2(2+2\lambda)(\frac{1}{2} + \frac{3}{2}\lambda) - 4(2+2\lambda) \end{aligned}$$

FR共轭梯度法--算例

$$\phi(\lambda) = (2+2\lambda)^2 + 2(\frac{1}{2} + \frac{3}{2}\lambda)^2 - 2(2+2\lambda)(\frac{1}{2} + \frac{3}{2}\lambda) - 4(2+2\lambda)$$

$$\text{令 } 0 = \phi'(\lambda),$$

$$\text{得 } \lambda_2 = 1, \quad x^2 + \lambda_2 p^2 = \begin{pmatrix} 2+2\lambda \\ \frac{1}{2} + \frac{3}{2}\lambda \end{pmatrix}$$

$\|g_3\| = 0 < \varepsilon$, 算法终止, 又该问题是凸规划,

$$\text{故得到极小点 } x^* = x^3 = \begin{pmatrix} 4 \\ 2 \end{pmatrix}.$$

FR共轭梯度法**共轭梯度法**

- 具有二次终止性: 从任意初始点出发, 最多 n 步迭代达到 n 元正定二次函数的极小点;
- 具有较高的求解效率: 共轭梯度法在一定条件下收敛, 且收敛速度通常优于最速下降法;
- 对非二次函数, 共轭梯度法产生的方向不再是共轭方向 (目标函数的Hesse矩阵不再是常数矩阵)。

FR共轭梯度法

收敛性定理:

设凸函数 f 存在一阶连续偏导数, 水平集 $L = \{x | f(x) \leq f(x^1)\}$

有界, 则由共轭梯度法得到的无穷点列 $\{x^k\}$ 具有如下性质:

- (1) $\{f(x^k)\}$ 为严格单调下降序列, 且 $\lim_{k \rightarrow \infty} f(x^k)$ 存在;
- (2) $\{x^k\}$ 的任意聚点 x^* 都是 f 的极小点。特点: 全局收敛

共轭梯度法在无约束优化方法中占有重要的地位,
是目前最常用的方法之一。

共轭梯度法--算法特点

(1) 求解凸函数的极小点时, 算法全局收敛;

(2) 适用于大规模问题

计算量小, 算法的计算公式简单, 不用求Hesse矩阵或
者逆矩阵;

存储量小, 每次迭代只需存储若干向量。

(3) 具有二次终止性

对于 n 元正定二次函数, 至多 n 次迭代可达到极小点。

共轭梯度法--算法特点

(4) 共轭梯度法的收敛速率不坏于最速下降法(Crowder 和Wolfe证明)

如果初始方向不用负梯度方向, 算法线性收敛;

(5) 共轭梯度法是目前求解无约束优化问题最常用的方法之一。

注: α_k 的不同公式, 对于正定二次函数来说是等价的,
对于非正定二次函数, 有不同的效果,
经验上PRP效果较好。

作业:

P 100 4.9, 4.10, 4.12, 4.13, 4.14,
4.17--4.19

变尺度法----一类特殊的拟Newton法

Newton法和阻尼Newton法收敛速度快, 但需要计算
Hesse矩阵的逆, $d^k = -(\nabla^2 f(x^k))^{-1} \nabla f(x^k)$, 计算量大, 存
储量也很大。

为减少计算量, 用一个 n 阶对称正定矩阵 H_k 近似代替
Hesse矩阵的逆 $(\nabla^2 f(x^k))^{-1}$, 即 $H_k \approx (\nabla^2 f(x^k))^{-1}$, 搜索方向
是 $p^k = -H_k g_k$, 由此产生的方法称为变尺度法, H_k 称为尺
度矩阵, 这是一种拟Newton法, 是无约束优化中最有效的
方法之一。

所谓拟Newton法是指由
Newton法的思想出发产生
的一类方法。

变尺度法——算法步骤

步骤1 任取初始点 x^1 ,初始尺度矩阵 H_1 ,令 $k=1$.

步骤2 计算 $p^k = -H_k g_k$.

步骤3 利用精确一维搜索找最佳步长 λ_k ,

$$x^{k+1} = x^k + \lambda_k p^k.$$

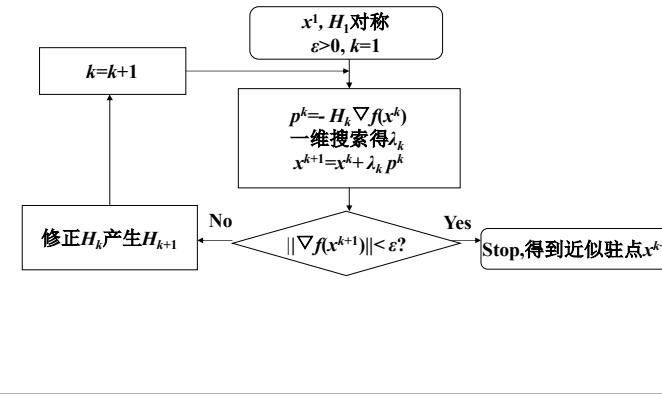
步骤4 如果 $\|\nabla f(x^{k+1})\| \leq \varepsilon$,停止, 得到近似驻点 x^{k+1} ; 否则转步骤5.

步骤5 令 $H_{k+1} = H_k + \Delta H_k$, $k = k + 1$ 转步骤2.

其中 ΔH_k 称为修正矩阵。

不同的修正矩阵, 对应着不同的变尺度法。

变尺度法——算法框架



变尺度法——一类特殊的拟Newton法

构造 H_k 的原则

变尺度法的关键——如何构造 H_k ,

为使算法有较快的收敛速度, H_k 需满足几个原则:

拟牛顿性质,

二次终止性,

稳定性。

变尺度法——一类特殊的拟Newton法

构造 H_k 的原则

拟牛顿性质

在 x^{k+1} 点处对函数 f 作二阶泰勒展开:

$$\begin{aligned} f(x) &= f(x^{k+1}) + (\nabla f(x^{k+1}))^T (x - x^{k+1}) \\ &\quad + \frac{1}{2} (x - x^{k+1})^T \nabla^2 f(x^{k+1}) (x - x^{k+1}) + o(\|x - x^{k+1}\|^2), \end{aligned}$$

略去高阶项,

$$f(x) \approx f(x^{k+1}) + (\nabla f(x^{k+1}))^T (x - x^{k+1}) + \frac{1}{2} (x - x^{k+1})^T \nabla^2 f(x^{k+1}) (x - x^{k+1}),$$

变尺度法——一类特殊的拟Newton法

$$f(x) \approx f(x^{k+1}) + (\nabla f(x^{k+1}))^T (x - x^{k+1}) + \frac{1}{2} (x - x^{k+1})^T \nabla^2 f(x^{k+1}) (x - x^{k+1}),$$

在 x^{k+1} 附近，上式两端求导，得

$$\nabla f(x) \approx \nabla f(x^{k+1}) + \nabla^2 f(x^{k+1})(x - x^{k+1}),$$

令 $x = x^k, g_k = \nabla f(x^k)$, 可得 $g_k \approx g_{k+1} + \nabla^2 f(x^{k+1})(x^k - x^{k+1})$,

$$g_{k+1} - g_k \approx \nabla^2 f(x^{k+1})(x^{k+1} - x^k),$$

记 $\Delta g_k = g_{k+1} - g_k, \Delta x_k = x^{k+1} - x^k$,

$$\Delta g_k \approx \nabla^2 f(x^{k+1}) \Delta x_k,$$

变尺度法——一类特殊的拟Newton法

构造 H_k 的原则——拟牛顿性质

$$\Delta g_k \approx \nabla^2 f(x^{k+1}) \Delta x_k,$$

Hesse 矩阵 $\nabla^2 f(x^{k+1})$ 对称正定，则 $H_k \approx (\nabla^2 f(x^k))^{-1}$

$$\Delta x_k \approx (\nabla^2 f(x^{k+1}))^{-1} \Delta g_k,$$

我们构造的 H_{k+1} 使之满足与上式类似的等式，即

$$\Delta x_k = H_{k+1} \Delta g_k, \quad (1)$$

拟牛顿性质（或条件或方程）

变尺度法——一类特殊的拟Newton法

构造 H_k 的原则——二次终止性

$$f(x) = \frac{1}{2} x^T A x + b^T x + c, A \text{ 对称正定}$$

把算法用于 n 元正定二次函数时，至多 n 次达到极小点。

构造的搜索方向 p^1, p^2, \dots, p^n 是一组 A 共轭向量组且 $H_{n+1} = A^{-1}$.

变尺度法——一类特殊的拟Newton法

构造 H_k 的原则——稳定性

若忽略计算过程的舍入误差，任意给定 k ，在算法的迭代点 x^k 处可选择步长，使得下个迭代点 x^{k+1} 处的函数值下降，则称此 **算法是稳定的**。

若 $p^k = -H_k g_k$ 是 f 在点 x^k 处的下降方向，则总能找到一个充分小的正数作为步长，使得 x^{k+1} 处的函数值下降，从而算法是稳定的。

$p^k = -H_k g_k$ 是下降方向，可保证算法是稳定的。

变尺度法——一类特殊的拟Newton法

构造 H_k 的原则---稳定性

$p^k = -H_k g_k$ 是下降方向, 可保证算法是稳定的。

在什么条件下 $p^k = -H_k g_k$ 是下降方向?

即在什么条件下, 能使得

$$(\nabla f(x^k))^T p^k = (g_k)^T p^k = -(g_k)^T H_k g_k < 0?$$

H_k 对称正定

变尺度法——一类特殊的拟Newton法

H_k 构造的要求

依据三个原则:

拟牛顿性质、二次收敛性和算法稳定性,

H_k 满足下列条件即可:

拟牛顿性质 $H_{k+1} \Delta g_k = \Delta x_k$,

对称正定、

且当 f 是 n 元正定二次函数时, p^1, p^2, \dots, p^n 是共轭向量组, 其中 $p^k = -H_k g_k, k=1, \dots, n$.

变尺度法——一类特殊的拟Newton法

H_k 的构造策略

构造对称正定的尺度矩阵 H_k 的一般策略是:

(1) H_1 取为任意一个 n 阶对称正定矩阵,

通常选取为 n 阶单位矩阵 I ;

(2) 然后通过修正 H_k , 给出 H_{k+1} , 令

$$H_{k+1} = H_k + \Delta H_k$$

构造不同的 H_k , 也就是构造不同的修正矩阵 ΔH_k , 得到不同的变尺度法。

下面介绍 DFP 变尺度法中 H_k 的构造过程。

DFP 算法 (Davidon(1959), Fletcher and Powell (1963))

DFP 算法中 H_k 的构造方法

构造 H_{k+1} 的三原则:

拟牛顿性质、二次终止性和稳定性,

DFP 算法构造 H_k 的过程, 首先要求 H_k

对称正定, 满足拟牛顿性质 $H_{k+1} \Delta g_k = \Delta x_k$.

为保证 H_{k+1} 的对称性, 令

$$H_{k+1} = H_k + \alpha_k u^k (u^k)^T + \beta_k v^k (v^k)^T,$$

α_k, β_k 是常数, u^k, v^k 是 n 维列向量。

H_1 是对称正定的矩阵。

DFP算法 (Davidon(1959), Fletcher and Powell (1963))

DFP算法中 H_k 的构造方法

DFP算法构造的 H_k : 对称正定满足拟牛顿性质

$$H_{k+1}\Delta g_k = \Delta x_k$$

$$H_{k+1} = H_k + \alpha_k u^k (u^k)^T + \beta_k v^k (v^k)^T$$

α_k, β_k 是常数, u^k, v^k 是n维列向量。

H_k 是对称正定的矩阵。

H_{k+1} 满足拟牛顿性质, $H_{k+1}\Delta g_k = \Delta x_k$,

$$\alpha_k u^k (u^k)^T \Delta g_k + \beta_k v^k (v^k)^T \Delta g_k = \Delta x_k - H_k \Delta g_k,$$

DFP算法 (Davidon(1959), Fletcher and Powell (1963))

DFP算法中 H_k 的构造方法

满足 $\alpha_k u^k (u^k)^T \Delta g_k + \beta_k v^k (v^k)^T \Delta g_k = \Delta x_k - H_k \Delta g_k$ 的 u^k 和 v^k 并不唯一。

简单的, 取 $\alpha_k u^k (u^k)^T \Delta g_k = \Delta x_k$, $\beta_k v^k (v^k)^T \Delta g_k = -H_k \Delta g_k$,

即 $\alpha_k (u^k)^T \Delta g_k u^k = \Delta x_k$, $\beta_k (v^k)^T \Delta g_k v^k = -H_k \Delta g_k$,

令 $\alpha_k (u^k)^T \Delta g_k = 1$, $u^k = \Delta x_k$, $\beta_k (v^k)^T \Delta g_k = -1$, $v^k = H_k \Delta g_k$,

$$\alpha_k = \frac{1}{(\Delta x_k)^T \Delta g_k},$$

$$\beta_k = -\frac{1}{(\Delta g_k)^T H_k \Delta g_k}$$

DFP算法

DFP算法中 H_k 的构造方法

$$H_{k+1} = H_k + \alpha_k u^k (u^k)^T + \beta_k v^k (v^k)^T \text{ 中}$$

$$u^k = \Delta x_k, v^k = H_k \Delta g_k,$$

$$\alpha_k = \frac{1}{(\Delta x_k)^T \Delta g_k}, \beta_k = -\frac{1}{(\Delta g_k)^T H_k \Delta g_k},$$

故

$$H_{k+1} = H_k + \frac{\Delta x_k (\Delta x_k)^T}{(\Delta x_k)^T \Delta g_k} - \frac{H_k \Delta g_k (\Delta g_k)^T H_k}{(\Delta g_k)^T H_k \Delta g_k}$$

-----DFP公式

DFP算法

定理1 若 $g_i \neq 0, i = 1, 2, \dots, n$, 则 DFP方法构造的矩阵 H_i ($i=1, 2, \dots, n$) 为对称正定矩阵。

证明 数学归纳法 (Schwartz不等式, 正定矩阵的性质,

精确一维搜索的结果。)

参见P92定理4.12的证明。

注: 此时搜索方向 $p^k = -H_k g_k$ 一定是下降方向。

DFP算法

定理1 若 $g_i \neq 0, i=1, 2, \dots, n$, 则DFP方法构造的矩阵 H_k ($k=1, 2, \dots, n$) 为对称正定矩阵。

证明 数学归纳法

当 $k=1$ 时, $H_1 = I$ 是对称正定矩阵;

假设 H_k 是对称正定矩阵, 证明 H_{k+1} 是对称正定的。

因为 H_k 是对称正定矩阵, 则由DFP公式可知

$$H_{k+1} = H_k + \frac{\Delta x_k (\Delta x_k)^T}{(\Delta x_k)^T \Delta g_k} - \frac{H_k \Delta g_k (\Delta g_k)^T H_k}{(\Delta g_k)^T H_k \Delta g_k}$$

H_{k+1} 是对称的, $(H_{k+1})^T = H_{k+1}$,

下证 H_{k+1} 是正定的:

$$H_{k+1} = H_k + \frac{\Delta x_k (\Delta x_k)^T}{(\Delta x_k)^T \Delta g_k} - \frac{H_k \Delta g_k (\Delta g_k)^T H_k}{(\Delta g_k)^T H_k \Delta g_k}$$

下证 H_{k+1} 是正定的: 任意给定非零 x

$$\begin{aligned} & ? \\ & 0 < x^T H_{k+1} x = x^T H_k x + \frac{x^T \Delta x_k (\Delta x_k)^T x}{(\Delta x_k)^T \Delta g_k} - \frac{x^T H_k \Delta g_k (\Delta g_k)^T H_k x}{(\Delta g_k)^T H_k \Delta g_k} \\ & = \frac{x^T H_k x (\Delta g_k)^T H_k \Delta g_k}{(\Delta g_k)^T H_k \Delta g_k} - \frac{x^T H_k \Delta g_k (\Delta g_k)^T H_k x}{(\Delta g_k)^T H_k \Delta g_k} + \frac{x^T \Delta x_k (\Delta x_k)^T x}{(\Delta x_k)^T \Delta g_k} \\ & = \frac{(x^T H_k x) ((\Delta g_k)^T H_k \Delta g_k) - (x^T H_k \Delta g_k)^2}{(\Delta g_k)^T H_k \Delta g_k} + \frac{(x^T \Delta x_k)^2}{(\Delta x_k)^T \Delta g_k} \\ & = (1) + (2) \end{aligned}$$

$$x^T H_{k+1} x = \frac{(x^T H_k x) ((\Delta g_k)^T H_k \Delta g_k) - (x^T H_k \Delta g_k)^2}{(\Delta g_k)^T H_k \Delta g_k} + \frac{(x^T \Delta x_k)^2}{(\Delta x_k)^T \Delta g_k}$$

$$= (1) + (2)$$

$$\text{先证 } (1) = \frac{(x^T H_k x) ((\Delta g_k)^T H_k \Delta g_k) - (x^T H_k \Delta g_k)^2}{(\Delta g_k)^T H_k \Delta g_k} \geq 0$$

$$\text{再证 } (2) = \frac{(x^T \Delta x_k)^2}{(\Delta x_k)^T \Delta g_k} \geq 0,$$

最后证 $x^T H_{k+1} x = (1) + (2) > 0$.

$$\text{先证 } (1) = \frac{(x^T H_k x) ((\Delta g_k)^T H_k \Delta g_k) - (x^T H_k \Delta g_k)^2}{(\Delta g_k)^T H_k \Delta g_k} \geq 0$$

因为 H_k 是正定的, 所以存在可逆矩阵 B , 使得 $H_k = B^T B$,

$$\begin{aligned} & (x^T H_k \Delta g_k)^2 = (x^T B^T B \Delta g_k)^2 = ((Bx)^T B \Delta g_k)^2 \\ & \leq (Bx)^T (Bx) \cdot (B \Delta g_k)^T (B \Delta g_k) \quad \text{Cauchy-Schwarz不等式} \\ & = (x^T B^T Bx) \cdot ((\Delta g_k)^T B^T B \Delta g_k) \\ & = (x^T H_k x) \cdot ((\Delta g_k)^T H_k \Delta g_k) \\ & (1) = \frac{(x^T H_k x) ((\Delta g_k)^T H_k \Delta g_k) - (x^T H_k \Delta g_k)^2}{(\Delta g_k)^T H_k \Delta g_k} \geq 0 \\ & “=” \Leftrightarrow x, \Delta g_k \text{ 线性相关} \end{aligned}$$

$$\begin{aligned}
& \text{再证 (2)} = \frac{(x^T \Delta x_k)^2}{(\Delta x_k)^T \Delta g_k} \geq 0, \\
(\Delta x_k)^T \Delta g_k &= (x^{k+1} - x^k)^T (g_{k+1} - g_k) \\
&= (x^k + \lambda_k p^k - x^k)^T (g_{k+1} - g_k) \\
&= \lambda_k (p^k)^T (g_{k+1} - g_k) \quad \text{精确一维搜索: } (g^{k+1})^T p^k = 0 \\
&= 0 - \lambda_k (p^k)^T g_k \quad p^k = -H_k g_k \\
&= -\lambda_k (-H_k g_k)^T g_k \\
&= \lambda_k (g_k)^T H_k g_k > 0 \quad g_k \neq 0, H_k \text{ 正定} \\
(2) &= \frac{(x^T \Delta x_k)^2}{(\Delta x_k)^T \Delta g_k} \geq 0, \quad \therefore x^T H_{k+1} x = (1) + (2) \geq 0,
\end{aligned}$$

下证 $x^T H_{k+1} x = (1) + (2) > 0$,
即证当(1)、(2)中有一个为零时, 另一个一定 > 0 .

$$(1) = \frac{(x^T H_k x) ((\Delta g_k)^T H_k \Delta g_k) - (x^T H_k \Delta g_k)^2}{(\Delta g_k)^T H_k \Delta g_k} \geq 0$$

$$(2) = \frac{x^T \Delta x_k (\Delta x_k)^T x}{(\Delta x_k)^T \Delta g_k} = \frac{(x^T \Delta x_k)^2}{(\Delta x_k)^T \Delta g_k} \geq 0,$$

设存在 $\alpha \in R$, 使得 $x = \alpha \Delta g_k$,

$$\begin{aligned}
x^T \Delta x_k &= x^T (x^{k+1} - x^k) = x^T (x^k + \lambda_k p^k - x^k) = \lambda_k x^T p^k \quad x = \alpha \Delta g_k \\
&= \lambda_k (\alpha \Delta g_k)^T p^k = \lambda_k \alpha (g_{k+1} - g_k)^T p^k = -\lambda_k \alpha (g_k)^T p^k \\
&= -\lambda_k \alpha (g_k)^T (-H_k g_k) \quad p^k = -H_k g_k \\
&= \lambda_k \alpha (g_k)^T H_k g_k
\end{aligned}$$

下证 $x^T H_{k+1} x = (1) + (2) > 0$,
即证当(1)、(2)中有一个为零时, 另一个一定 > 0 .

$$(1) = \frac{(x^T H_k x) ((\Delta g_k)^T H_k \Delta g_k) - (x^T H_k \Delta g_k)^2}{(\Delta g_k)^T H_k \Delta g_k} \geq 0$$

$$(2) = \frac{x^T \Delta x_k (\Delta x_k)^T x}{(\Delta x_k)^T \Delta g_k} = \frac{(x^T \Delta x_k)^2}{(\Delta x_k)^T \Delta g_k} \geq 0,$$

设存在 $\alpha \in R$, 使得 $x = \alpha \Delta g_k$,

$$\begin{aligned}
x^T \Delta x_k &= x^T (x^{k+1} - x^k) = x^T (x^k + \lambda_k p^k - x^k) = \lambda_k x^T p^k \quad x = \alpha \Delta g_k \\
&= \lambda_k (\alpha \Delta g_k)^T p^k = \lambda_k \alpha (g_{k+1} - g_k)^T p^k = -\lambda_k \alpha (g_k)^T p^k \\
&= -\lambda_k \alpha (g_k)^T (-H_k g_k) \quad p^k = -H_k g_k \\
&= \lambda_k \alpha (g_k)^T H_k g_k
\end{aligned}$$

下证 $x^T H_{k+1} x = (1) + (2) > 0$,
即证当(1)、(2)中有一个为零时, 另一个一定 > 0 .

$$(1) = \frac{(x^T H_k x) ((\Delta g_k)^T H_k \Delta g_k) - (x^T H_k \Delta g_k)^2}{(\Delta g_k)^T H_k \Delta g_k} \geq 0$$

$$(2) = \frac{x^T \Delta x_k (\Delta x_k)^T x}{(\Delta x_k)^T \Delta g_k} = \frac{(x^T \Delta x_k)^2}{(\Delta x_k)^T \Delta g_k} \geq 0,$$

设存在 $\alpha \in R$, 使得 $x = \alpha \Delta g_k$, 则 $x^T \Delta x_k = \lambda_k \alpha (g_k)^T H_k g_k$,

当(1)=0时, $x, \Delta g_k$ 线性相关, 则 $\alpha \neq 0$, 注意 $g_k \neq 0, H_k$ 正定,

故 $x^T \Delta x_k = \lambda_k \alpha (g_k)^T H_k g_k \neq 0$, 因此(2)>0.

当(2)=0时, 由 $x^T \Delta x_k = \lambda_k \alpha (g_k)^T H_k g_k = 0$ 可知, $\alpha = 0$,

故 $x, \Delta g_k$ 线性无关, 因此(1)>0.

DFP算法

定理2 设用DFP算法求解下列问题

DFP算法最多 n 步必达到正定二次函数极小点,
 $\min f(x) = x^T Ax + b^T x + c$
 具有二次终止性。

其中 A 为 n 阶对称正定矩阵。由DFP方法产生的搜索方向
 为 p^1, p^2, \dots, p^n , 对应的尺度矩阵为 H_1, H_2, \dots, H_n , 则

$$(1) \quad (p^i)^T g_j = 0, \quad 1 \leq i < j \leq n$$

$$(2) \quad H_j A p^i = p^i, \quad 1 \leq i < j \leq n$$

(3) 表明DFP方法也是一种
 共轭方向法。

证明 参见P93定理4.14的证明

若 H_1 是单位矩阵, 则 $p^1 = -H_1 \nabla f(x^1) = -\nabla f(x^1)$,

DFP方法也是一种共轭梯度法。

DFP算法--算法步骤

步骤1 选定初始点 x^1 , 初始矩阵 $H_1 = I_n$, $\varepsilon > 0$.

步骤2 如果 $\|g_1\| \leq \varepsilon$, 停止, 得到近似驻点 x^1 , 否则转步骤3。

步骤3 取 $p^1 = -H_1 g_1$, $k=1$.

步骤4 精确一维搜索找最佳步长 λ_k , 令 $x^{k+1} = x^k + \lambda_k p^k$.

步骤5 如果 $\|g_{k+1}\| \leq \varepsilon$, 停止, 得到近似驻点 x^{k+1} , 否则转步骤6。

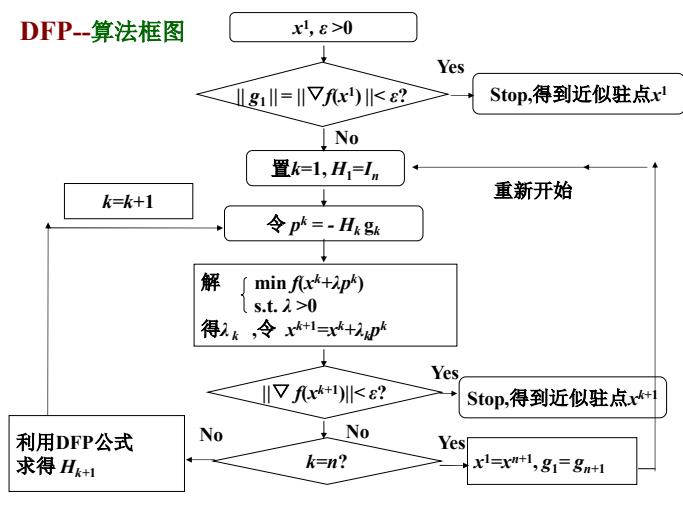
步骤6 如果 $k=n$, 令 $x^1 = x^{k+1}$, $p^1 = -g_{k+1}$, $k=1$, 转步骤4; 否则转步骤7。

步骤7 令 $\Delta x_k = x^{k+1} - x^k$, $\Delta g_k = g_{k+1} - g_k$, $r_k = H_k \Delta g_k$,

$$\text{计算 } H_{k+1} = H_k + \frac{\Delta x_k (\Delta x_k)^T}{(\Delta x_k)^T \Delta g_k} - \frac{r_k (r_k)^T}{(\Delta g_k)^T H_k \Delta g_k}$$

和 $p^{k+1} = -H_{k+1} g_{k+1}$, 令 $k = k + 1$, 转步骤4.

DFP--算法框图



DFP算法-算例

例 用DFP算法求 $\min f(x) = 2x_1^2 + x_2^2 - 4x_1 + 2$,

取 $x^1 = (2, 1)^T$, $\varepsilon = 10^{-3}$.

解 计算函数 f 的梯度函数: $g(x) = \begin{pmatrix} 4(x_1 - 1) \\ 2x_2 \end{pmatrix}$,

1) 第一次迭代

在初始点 x^1 处的梯度为: $g_1 = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$, 取 $H_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$,

$$p^1 = -H_1 g_1 = -\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 4 \\ 2 \end{pmatrix} = \begin{pmatrix} -4 \\ -2 \end{pmatrix},$$

$$x^1 + \lambda p^1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix} + \lambda \begin{pmatrix} -4 \\ -2 \end{pmatrix} = \begin{pmatrix} 2 - 4\lambda \\ 1 - 2\lambda \end{pmatrix}$$

DFP算法--算例

$$x^1 + \lambda p^1 = \begin{pmatrix} 2-4\lambda \\ 1-2\lambda \end{pmatrix}, \quad g(x) = \begin{pmatrix} 4(x_1-1) \\ 2x_2 \end{pmatrix},$$

精确一维搜索求最佳步长,

$$\begin{aligned}\phi(\lambda) &= f(x^1 + \lambda p^1) = f(2-4\lambda, 1-2\lambda) \\ &= 2(2-4\lambda)^2 + (1-2\lambda)^2 - 4(2-4\lambda) + 2\end{aligned}$$

$$\text{令 } 0 = \phi'(\lambda) = 4(2-4\lambda)(-4) + 2(1-2\lambda)(-2) - 4 \times (-4),$$

$$\text{得 } \lambda_1 = \frac{5}{18},$$

$$\begin{aligned}x^2 &= x^1 + \lambda_1 p^1 = \begin{pmatrix} 2-4\lambda \\ 1-2\lambda \end{pmatrix} \Big|_{\lambda=\lambda_1=\frac{5}{18}} = \begin{pmatrix} 8/9 \\ 4/9 \end{pmatrix}, \quad g_2 = g(x_2) = \begin{pmatrix} -4/9 \\ 8/9 \end{pmatrix}, \\ \|g_2\| &= \frac{4\sqrt{5}}{9} > \varepsilon, \quad \text{继续迭代};\end{aligned}$$

DFP算法--算例

$$H_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix},$$

2) 第二次迭代

$$\Delta x_1 = x^2 - x^1 = \lambda_1 p^1 = \frac{5}{18} \begin{pmatrix} -4 \\ -2 \end{pmatrix} = \begin{pmatrix} -10/9 \\ -5/9 \end{pmatrix},$$

$$\Delta g_1 = g_2 - g_1 = \begin{pmatrix} -4/9 \\ 8/9 \end{pmatrix} - \begin{pmatrix} 4 \\ 2 \end{pmatrix} = \begin{pmatrix} -40/9 \\ -10/9 \end{pmatrix},$$

$$\begin{aligned}H_2 &= H_1 + \frac{\Delta x_1 \Delta x_1^T}{\Delta g_1^T \Delta x_1} - \frac{H_1 \Delta g_1 \Delta g_1^T H_1}{\Delta g_1^T H_1 \Delta g_1} \\ &= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + \frac{\begin{pmatrix} -10/9 \\ -5/9 \end{pmatrix} \begin{pmatrix} -10/9, -5/9 \end{pmatrix}}{\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} -40/9 \\ -10/9 \end{pmatrix}} - \frac{\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} -40/9, -10/9 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}}{\begin{pmatrix} -40/9, -10/9 \\ -10/9 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} -40/9 \\ -10/9 \end{pmatrix}}\end{aligned}$$

DFP算法--算例

$$\begin{aligned}H_2 &= H_1 + \frac{\Delta x_1 \Delta x_1^T}{\Delta g_1^T \Delta x_1} - \frac{H_1 \Delta g_1 \Delta g_1^T H_1}{\Delta g_1^T H_1 \Delta g_1} \\ &= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + \frac{1}{18} \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} - \frac{1}{17} \begin{pmatrix} 16 & 4 \\ 4 & 1 \end{pmatrix} = \frac{1}{306} \begin{pmatrix} 86 & -38 \\ -38 & 305 \end{pmatrix}\end{aligned}$$

$$\text{令 } p^2 = -H_2 g_2 = -\frac{1}{306} \begin{pmatrix} 86 & -38 \\ -38 & 305 \end{pmatrix} \begin{pmatrix} -4/9 \\ 8/9 \end{pmatrix} = \frac{12}{51} \begin{pmatrix} 1 \\ -4 \end{pmatrix},$$

$$x^2 + \lambda p^2 = \begin{pmatrix} 8/9 \\ 4/9 \end{pmatrix} + \lambda \times \frac{12}{51} \begin{pmatrix} 1 \\ -4 \end{pmatrix} = \begin{pmatrix} 8/9 + \frac{12}{51} \lambda \\ 4/9 - 4 \times \frac{12}{51} \lambda \end{pmatrix},$$

DFP算法--算例

$$x^2 + \lambda p^2 = \begin{pmatrix} 8/9 + \frac{12}{51} \lambda \\ 4/9 - 4 \times \frac{12}{51} \lambda \end{pmatrix},$$

精确一维搜索求最佳步长,

$$\phi(\lambda) = f(x^2 + \lambda p^2) = f(8/9 + \frac{12}{51} \lambda, 4/9 - 4 \times \frac{12}{51} \lambda)$$

$$\text{令 } 0 = \phi'(\lambda), \quad \text{得 } \lambda_2 = 17/36,$$

$$x^3 = x^2 + \lambda_2 p^2 = \begin{pmatrix} 8/9 + \frac{12}{51} \times \frac{17}{36} \\ 4/9 - 4 \times \frac{12}{51} \times \frac{17}{36} \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad g_3 = \nabla f(x^3) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad \|g_3\| = 0 < \varepsilon,$$

算法终止, 又该问题是凸规划, 得到最优解: $x^* = x^3 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$.

DFP算法--收敛性分析

收敛性定理:

设凸函数 f 存在一阶连续偏导数, 水平集 $L = \{x | f(x) \leq f(x^1)\}$

有界, 则由DFP法得到的无穷点列 $\{x^k\}$ 具有如下性质:

(1) $\{f(x^k)\}$ 为严格单调下降序列, 且 $\lim_{k \rightarrow \infty} f(x^k)$ 存在;

(2) $\{x^k\}$ 的任意聚点 x^* 都是 f 的极小点。特点: 全局收敛性

定理(精确一维搜索迭代法的收敛性) θ_k 是 d^k 与 $-\nabla f(x^k)$ 的夹角
是目前最常用的方法之一。
设 $\lambda_k = \arg \min f(x^k + \lambda d^k)$, $\nabla f(x)$ 在 $L = \{x \in R^n : f(x) \leq f(x^1)\}$
上存在且一致连续, $\theta_k \leq \frac{\pi}{2} - \mu (\exists \mu > 0)$, 则或者存在某个 k
使得 $\nabla f(x^k) = 0$, 或者 $\nabla f(x^k) \rightarrow 0$, 或者 $f(x^k) \rightarrow \infty$

DFP算法--优缺点

优点:

(1) DFP算法具有二次收敛性

当 $f(x) = 1/2x^T Ax + b^T x + c$ (A 对称正定)时, 由DFP算法
产生的方向 p^1, p^2, \dots, p^n 是 A -共轭向量组, 故DFP算
法最多 n 次迭代就可达到 f 的极小点。

DFP算法实质上是一种共轭方向法。

DFP算法--优缺点

优点:

(2) 求解凸函数的极小点时, DFP算法全局收敛;

(3) 对非二次函数, DFP算法的效果也很好,

收敛速度是超线性的,

它比最速下降法和共轭梯度法要有效的多。

DFP算法--优缺点

缺点:

(1) DFP算法的计算量、存储量要比共轭梯度法大,
对大规模优化问题, 用共轭梯度法更方便。

(2) 实际运算中, 舍入误差和一维搜索的不精确, 都会对DFP
算法的稳定性和计算效率产生很大的影响; 但BFGS算法
受到的影响要小得多。

BFGS算法

由前面的推导 $\Delta x_k \approx (\nabla^2 f(x^{k+1}))^{-1} \Delta g_k$, 则

$$\Delta g_k \approx \nabla^2 f(x^{k+1}) \Delta x_k,$$

令 B_{k+1} 满足

$$\Delta g_k = B_{k+1} \Delta x_k, \quad (2)$$

公式(2)称为另一种拟牛顿性质(或称拟牛顿条件或方程)。

上面的公式(2)只需要交换 $\Delta g_k, \Delta x_k$ 就可以得到前面的拟牛顿性质:

$$\Delta x_k = H_{k+1} \Delta g_k \quad (1)$$

BFGS算法

因此只需要在 H_k 的递推公式

$$H_{k+1} = H_k + \frac{\Delta x_k (\Delta x_k)^T}{(\Delta x_k)^T \Delta g_k} - \frac{H_k \Delta g_k (\Delta g_k)^T H_k}{(\Delta g_k)^T H_k \Delta g_k}$$

互换 $\Delta g_k, \Delta x_k$, 并用 B_{k+1}, B_k 分别取代 H_{k+1}, H_k , 就得到 B_k 的递推公式,

$$B_{k+1} = B_k + \frac{\Delta g_k (\Delta g_k)^T}{(\Delta g_k)^T \Delta x_k} - \frac{B_k \Delta x_k (\Delta x_k)^T B_k}{(\Delta x_k)^T B_k \Delta x_k} \quad (3)$$

该公式称为关于矩阵 B_k 的 **BFGS修正公式**, 有时也称为 **DFP的对偶公式**。

BFGS算法

设 B_{k+1} 可逆, 则由(2)

$$\Delta g_k = B_{k+1} \Delta x_k \quad (2)$$

$$\text{可知 } \Delta x_k = (B_{k+1})^{-1} \Delta g_k \quad (4)$$

所以 $(B_{k+1})^{-1}$ 满足拟牛顿条件 $\Delta x_k = H_{k+1} \Delta g_k$, 令 $H_{k+1} = (B_{k+1})^{-1}$

对(3)两边求导, 求导方法见文 (陈宝林),

$$B_{k+1} = B_k + \frac{\Delta g_k (\Delta g_k)^T}{(\Delta g_k)^T \Delta x_k} - \frac{B_k \Delta x_k (\Delta x_k)^T B_k}{(\Delta x_k)^T B_k \Delta x_k} \quad (3)$$

得到

BFGS算法

$$H_{k+1}^{BFGS} = H_k + \left(1 + \frac{(\Delta g_k)^T H_k \Delta g_k}{\Delta x_k^T \Delta g_k} \right) \frac{\Delta x_k \Delta x_k^T}{\Delta x_k^T \Delta g_k} - \frac{\Delta x_k (\Delta g_k)^T H_k + H_k \Delta g_k \Delta x_k^T}{(\Delta x_k)^T \Delta g_k} \quad (5)$$

-----BFGS公式

这个重要公式由Broyden(布洛伊登), Fletcher(弗莱彻), Goldfarb(戈德法布)和Shanno于1970年提出。

BFGS公式应用广泛, 数值计算实例表明, 它比DFP公式的效果要好。

BFGS算法具有变尺度法的全部优点, 在一定条件下, 使用非精确一维搜索的BFGS算法具有全局收敛性。

Broyden（布洛伊登）族变尺度法

将DFP公式记为

$$H_{k+1}^{DFP} = H_k + \frac{\Delta x_k (\Delta x_k)^T}{(\Delta x_k)^T \Delta g_k} - \frac{H_k \Delta g_k (\Delta g_k)^T H_k}{(\Delta g_k)^T H_k \Delta g_k} \quad (6)$$

结合BFGS公式，

$$\begin{aligned} H_{k+1}^{BFGS} &= H_k + \left(1 + \frac{(\Delta g_k)^T H_k \Delta g_k}{\Delta x_k^T \Delta g_k} \right) \frac{\Delta x_k \Delta x_k^T}{\Delta x_k^T \Delta g_k} \\ &\quad - \frac{\Delta x_k (\Delta g_k)^T H_k + H_k \Delta g_k \Delta x_k^T}{(\Delta x_k)^T \Delta g_k} \end{aligned} \quad (5)$$

引入参数 φ , 有

Broyden族变尺度法

$$H_{k+1}^\varphi = (1 - \varphi) H_{k+1}^{DFP} + \varphi H_{k+1}^{BFGS} \quad (7)$$

将(5)和(6)代入(7), 得到

$$H_{k+1}^\varphi = H_{k+1}^{DFP} + \varphi v^k (v^k)^T, \quad (8)$$

其中

$$v^k = \left((\Delta g_k)^T H_k \Delta g_k \right)^{1/2} \left(\frac{\Delta x_k}{(\Delta x_k)^T \Delta g_k} - \frac{H_k \Delta g_k}{(\Delta g_k)^T H_k \Delta g_k} \right)$$

将(7)或者(8)给出的修正公式的全体称为Broyden族。

当 $\varphi=0$ 时, 即为DFP公式; 当 $\varphi=1$ 时, 即为BFGS公式。

Broyden族变尺度法

由于DFP和BFGS公式都满足拟牛顿性质, 因此Broyden族的所有成员也满足拟牛顿性质。

Broyden族的任何一个成员都具有一般变尺度法的优点; DFP算法所具有的许多性质, Broyden族算法也有。

在拟Newton法的每次迭代中, 可用Broyden族的任意一个成员作为修正公式。

Broyden族含有一个参数, 给出了一类拟Newton算法; Huang族含有三个参数, 也给出了一类拟Newton算法; Broyden族是Huang族的一个子族。

第四章作业

P99 4.1 4.2 4.4 4.5 4.9 4.10 4.12--4.14
4.17--4.19 4.23 4.26(初始点取 $(1,1)^T$)

4.3 建议编程

迭代14次得到近似解 $(-0.6344, -0.0032)^T$, 近似最优值为-0.4724.